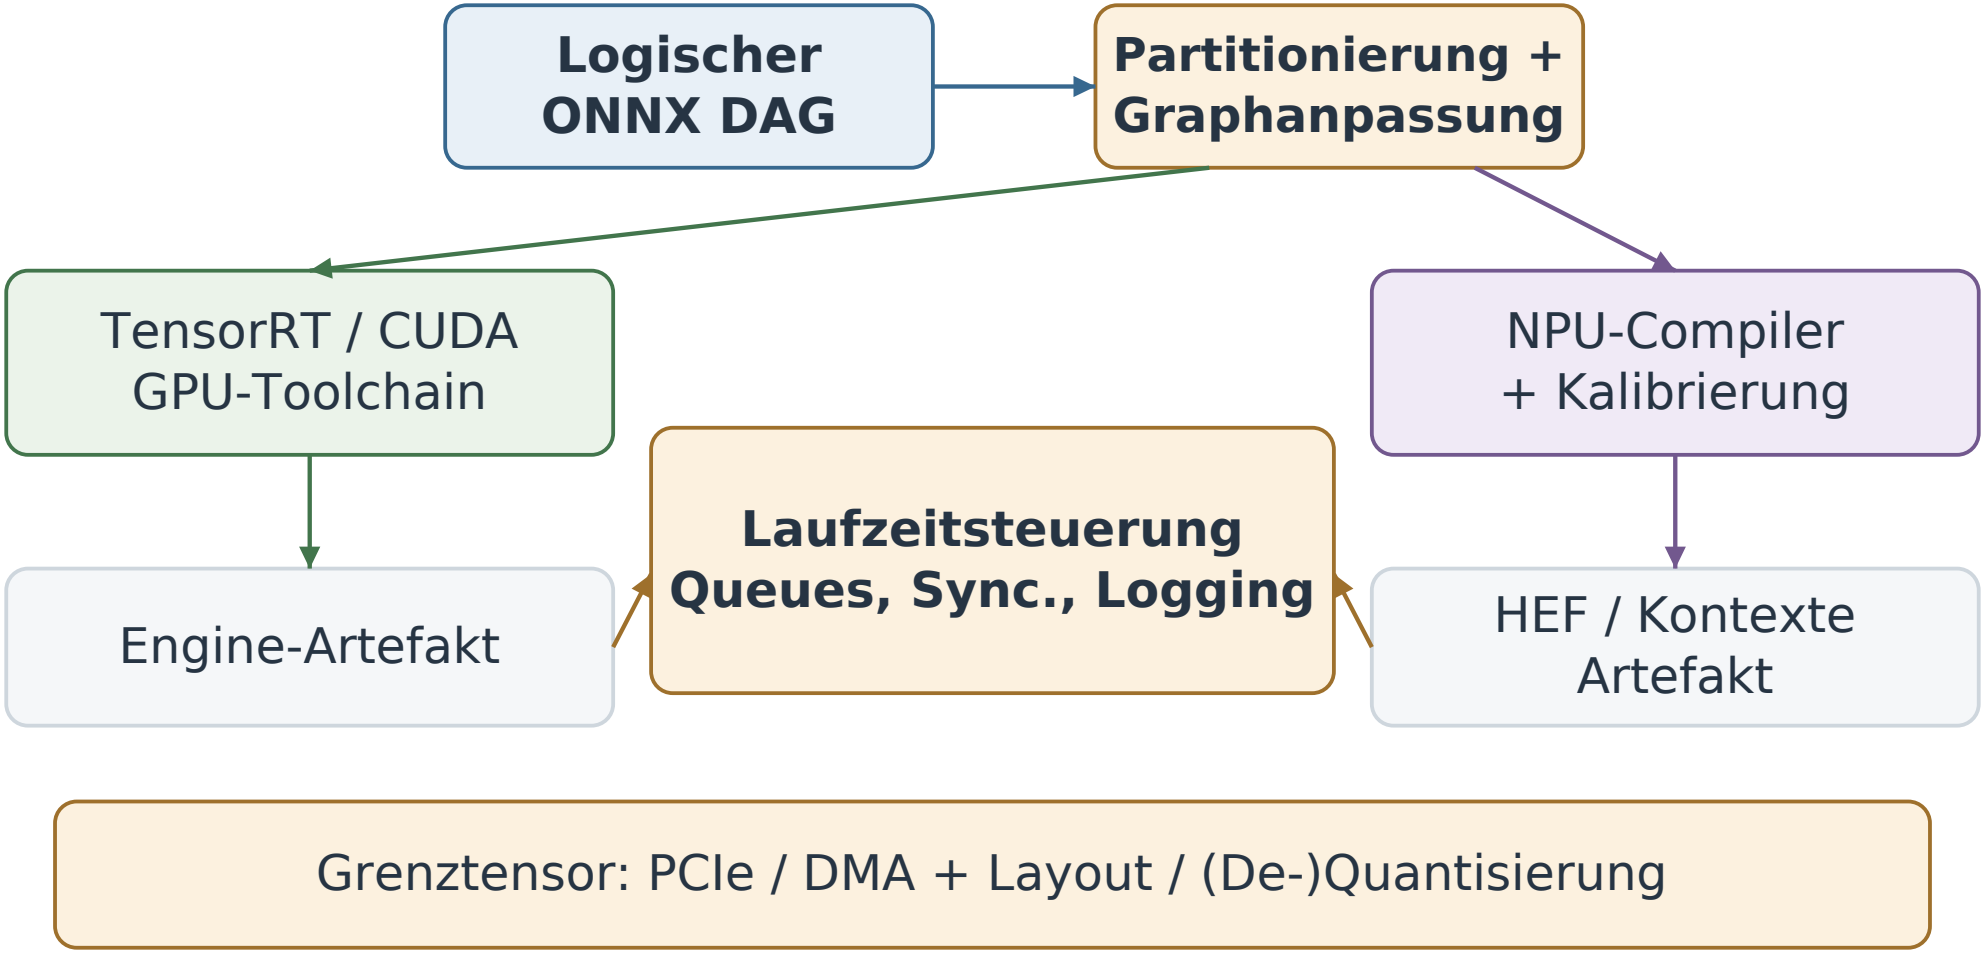

Logischer
ONNX DAG
Partitionierung +
Graphanpassung
TensorRT / CUDA
GPU-Toolchain
NPU-Compiler
+ Kalibrierung
Laufzeitsteuerung
Queues, Sync., Logging
Engine-Artefakt
HEF / Kontexte
Artefakt
Grenztensor: PCIe / DMA + Layout / (De-)Quantisierung