Ergänzende Methoden und Prüfprotokolle

Kevin Mika · Dissertation · Archivfassung vom 11. November 2026

Dieses Begleitdokument bewahrt die ausführliche Anhangfassung vor ihrer redaktionellen Kürzung. Es enthält die ursprünglichen Methodenangaben, Prüfprotokolle, Ergebnistabellen und alle sieben Modellansichten.

Die Abschnitts-, Seiten-, Tabellen-, Abbildungs- und Literaturnummern der ursprünglichen Fassung bleiben erhalten. Verweise auf den Haupttext beziehen sich auf diese Fassung. Das zugehörige Literaturverzeichnis ist am Ende angefügt.

Originalabschnitt	Inhalt
A	KI-gestützte Werkzeugentwicklung
B	Datenquellen, Energiemessung und Prüfprotokolle
C	Split-Inferenz, Zählregeln und Entwicklungsprüfungen
D	Vollständige Modellansichten

Die Messdaten und Ergebnisse wurden bei der Auslagerung nicht verändert. Der README dieses Ergänzungspakets ordnet die Inhalte den zugehörigen Dateien und numerischen Auswertungen im Ergebnisarchiv zu.

Grundlage: der bereitgestellte Projektstand Dissertation_Lean_Kapitel5(1)(1).zip. Die ursprünglichen LaTeX-Quellen und alle Modellansichten sind zusätzlich im Ergänzungspaket enthalten.

Anhang

A Dokumentation der KI-gestützten Werkzeugentwicklung

A.1 Geltungsbereich und Zuständigkeit

Das ONNX Splitpoint Tool wurde im Rahmen umfangreicher, promptgesteuerter Arbeiten mit ChatGPT und Codex von OpenAI [120, 121] entwickelt. Diese Systeme erzeugten oder überarbeiteten einen wesentlichen Teil der Implementierungsentwürfe und wurden in späteren Phasen zur vorherrschenden Quelle für Code-Entwürfe und -Überarbeitungen. Dieser Anhang ergänzt den Entwicklungsbericht in Abschnitt 7.6.

Der Autor konzipierte das Tool, stellte die ursprünglichen Python-Skripte und -Modelle bereit und definierte die Forschungsfragen, Anforderungen sowie Akzeptanzkriterien. Er wählte die Zielplattformen und Bewertungsmethoden aus, betrieb die Versuchssysteme und bewertete die daraus resultierenden Erkenntnisse. Er wählte vorgeschlagene Änderungen aus, integrierte, testete, modifizierte oder lehnte sie ab. Die Verantwortung für die eingereichte Software, das Versuchsdesign, die Interpretation und das Manuskript liegt beim Autor.

Die Unterstützung umfasste Graphen- und Kostenanalysen, den Export von Split-Modellen, Schnittstellen, Backend-Integration, Ablaufsteuerung, Validierung der Aufgabenqualität, Energieorchestrierung, Tests und Berichterstellung. Der Autor nutzte beobachtete Fehler und Zwischenergebnisse, um nachfolgende Änderungen zu steuern. Die Verifikation bezog sich auf das für jede Aussage erforderliche Verhalten. Überlappende Patches, Refactoring, Rückgängigmachungen und manuelle Integration verhindern eine aussagekräftige prozentuale Ermittlung der Netto-Code-Urheberschaft.

Die Beiträge von Joris Wachsmuth und dem Autor zur Messinfrastruktur und Auswertung sind in Abschnitt 4.3 beschrieben.

A.2 Werkzeuge, Entwicklung und Verifikation

Das gespeicherte Register erfasst die Nutzung von ChatGPT ab dem 25. August 2025 und die Nutzung von Codex ab dem 14. Februar 2026. ChatGPT unterstützte den Anforderungsdialog, die Erstellung von Architektur- und Metrikvorschlägen, die Codegenerierung sowie das Debugging anhand von Protokollen und der Dokumentation. Codex unterstützte die Repository-Implementierung, Refactoring, Tests, Diffs und die Release-Paketierung. Ihre Rollen überschnitten sich, da Diskussionen zu Codeänderungen führten und Hardwareergebnisse weitere Überarbeitungen erforderten.

Die Metadaten der Konversation erfassen folgende Modellkennungen:

```
gpt-5-pro    gpt-5-2-pro       gpt-5-4-pro
gpt-5-5-pro  gpt-5-5-thinking  gpt-5-5
gpt-5-mini
```

Einigen Codex-Arbeitsaufträgen und späteren Interaktionen fehlt eine zuverlässige Modellkennung. Diese Kennungen sind nicht verfügbar und werden nicht aus dem Gedächtnis rekonstruiert.

Die Entwicklung schritt von der statischen Graphenanalyse und dem Split-Export über die Backend-Integration und Validierung der Laufzeit bis hin zur experimentellen Orchestrierung voran. Hardwareausfälle und Messergebnisse flossen in Überarbeitungen der Tensor-Schnittstellen, der Ablaufsteuerung und der Ausgabeverarbeitung ein. Der aufbewahrte Code, die Testprotokolle und die Messaufzeichnungen belegen, welche vorgeschlagenen Änderungen umgesetzt und überprüft wurden.

Die Verifikation umfasste die Überprüfung der ONNX-Tensorformen, Vergleiche zwischen vollständigen und zusammengesetzten Modellen, Überprüfungen der Tensor-Schnittstelle sowie die Ausführung auf dem Zielsystem. Bei der Auswertung des Datensatzes wurden die Ergebnisse der Klassifikation und Erkennung überprüft. Kalibrierte Messverläufe, Zeitfenster und Zählungen der abgeschlossenen Arbeitsschritte dienten der Energieanalyse. Unit- und Integrationstests ergänzten diese Hardwareprüfungen. Wissenschaftliche Aussagen stützen sich auf die getestete Software und die Messprotokolle, nicht auf generierte Erklärungen.

A.3 Aufbewahrung der Entwicklungsunterlagen

Die Unterstützung bei der Manuskripterstellung ist in der abschließenden Erklärung *Nutzung KI-gestützter Werkzeuge* beschrieben. Sie umfasste auch die Integration der gemeinsam verfassten Manuskripte in das Ergebnisrepositorium, die numerische Neuauswertung gespeicherter Exporte und die Bearbeitung von Gutachten.

Der Revisionsverlauf und das Projektregister enthalten die Entwicklungsentscheidungen, Codeänderungen, Testberichte und Messquellen. Abgeleitete Analysen behalten ihre Ausgangspopulationen und Messdefinitionen bei. AI-Unterstützungsaufzeichnungen dokumentieren den Entwicklungsprozess getrennt von den in Anhang B abgebildeten numerischen Belegen.

Der vollständige Export der Konversation enthält zudem nicht themenbezogene und persönliche Inhalte und verbleibt in einem zugriffsgeschützten Archiv. Ein projektspezifisches Verzeichnis kann relevante Konversationen und Nachrichten identifizieren, ohne dieses Material zu veröffentlichen. Die Aufzeichnungen enthalten weder jede Modellkennung noch eine vollständige Historie der Urheberschaft für jede einzelne Bearbeitung. Anhang B ordnet wissenschaftliche Ergebnisse ihren Quellen zu. Entwicklungsgespräche dokumentieren die Unterstützung getrennt von den Messdaten.

B Datenquellen und Reproduzierbarkeit

B.1 Quellen und Verfügbarkeit

Die zentrale Sammlung *Edge AI Performance and Energy Results* [96] enthält die in dieser Dissertation verwendeten numerischen Eingaben und die Analysesoftware. Tabelle B.1 gibt die wichtigsten Einstiegspunkte an. Der Einsatzvergleich, der gepaarte Vergleich der Ausführungsmodule und die umfassendere Graphenauswertung stützen sich auf die in Kapitel 8 beschriebene Kampagne. Unabhängige Energie- und Laufzeitversuche verfügen über eigene Messprotokolle.

Tabelle B.1: Quellenübersicht. Pfade beziehen sich auf das zentrale Ergebnisrepositorium.

Beweismittel	Einstiegspunkt des Repositorys
Energiemessung	`results/energy-measurement/`: Rekonstruktion, Spektren, Messgerätevergleiche, Kalibrierung und Protokollkontrollen.
Vergleich der Ausführungskonfigurationen	`results/split-inference/`: Qualität, Zeitablauf, Energie, Wiederholungen und Full-Referenzen.
Auswahl und unterstützende Studien	`results/supplementary-studies/`: Rangfolgen der Kandidaten, angepasste Werte, stufenweise Auswahl und Laufzeitprüfungen.
Zuordnung der Veröffentlichungen	`publications/`: Quellkarten für Manuskripte und Dissertationen.
Reproduktionssoftware	`scripts/` und `software/`: Analysebefehle und gespeicherte Softwarequellen.

Der fertige Datensatz wurde in der Revision `0a45553836acf91a4faad80adc1779af99591b53` veröffentlicht. Die numerischen Analysen basieren auf `aed301819663b5fa27bd5731fb74fef3e46ee927`. Die exportierten Abbildungen der Dissertation sowie die Software werden in der Revision `3cc8ad92fb1a58e6e793561e489d323e19f15a01` veröffentlicht. Ihre Quell- und Ausgabe-Hashes sind im LaTeX-Projekt erfasst. Die separate Studie mit kontinuierlicher Eingabe verwendet die Revision `6ebc90deca31c9890d7ebccd7fd2981f8bda0c96` [97].

Große Modelle, Hersteller-Binärdateien, Datensatzbilder, vollständige Vorhersagen und Rohwellenformen werden in externen Erfassungsarchiven aufbewahrt. Die Wiederholung physikalischer Messungen erfordert diese Eingaben, ihre Softwareumgebungen sowie die Zielsysteme. Ihre Verfügbarkeit und ihre Weiterverbreitungsrechte unterscheiden sich von denen der veröffentlichten numerischen Exporte. Die nachstehenden

Reproduktionsbefehle erzeugen Analysen aus aufgezeichneten Ergebnissen neu, ohne die Hardware-Messungen zu wiederholen.

B.1.1 Energie- und Manuskriptquellen

Die drei Manuskripte des Autors enthalten die Energiestudien und die Split-Selection-Studie [98, 100, 101]. Die Selektionsanalyse folgt dem abschließenden MLSys-Manuskript. Kapitel 4 verwendet die gesamte FP16-Population mit allen fünfzehn Elementen sowie die korrigierte native Referenzrekonstruktion. Die numerischen Eingabedaten sind unter `results/energy-measurement/` archiviert, die zugehörigen Quellen der Dissertation unter `results/supplementary-studies/dissertation-v56/`. Die Referenz [99] verweist auf die früher festgelegte Sammlung von Energiedaten. Das aktuelle Repository enthält deren Eingabedaten sowie die Exporte aus der Dissertation.

Numerische Exporte geben die berichteten Zusammenfassungen wieder. Spektralschätzung und Wellenformrekonstruktion erfordern zusätzlich die Rohaufzeichnungen oder verifizierten Caches sowie deren Erfassungseinstellungen. Rekonstruktion, physikalische Abtastung und Vergleiche mit eingesetzten Messgeräten testen unterschiedliche Effekte. Kapitel 4 definiert deren elektrische und zeitliche Geltungsbereiche.

B.2 Reproduktion von Abbildungen und Tabellen

Nach dem Auschecken der oben genannten Überarbeitung des Abbildungsexports generiert der folgende Befehl die englischen Publikationsartefakte aus den aufgezeichneten Messungen neu:

```
python3 scripts/reproduce_current.py \
  --output local-output/current --languages en
```

Die Installation der Abhängigkeiten wird in `scripts/README.md` beschrieben. Zu den in `scripts/split-inference/requirements-r30.txt` festgelegten Abhängigkeiten gehören pandas und SciPy für die Datenverarbeitung und numerische Auswertung [92, 158] sowie Matplotlib für Diagramme und PyMuPDF für die PDF-Verarbeitung [64, 126]. Die Datei `results/ACTIVE_GENERIC420.json` identifiziert die Kampagneneingaben. Die gepaarten, umfassenderen Generic- und stufenweisen Analysen sind unter `results/supplementary-studies/rq2-native-scope-20261027/`, `rq3-generic420-detector-corrected-20261027/` und `staged-selection/` enthalten.

Der Abbildungsgenerator für Dissertationen verwendet dieselben numerischen Eingaben:

```
python3 scripts/dissertation/export_thesis_selection.py \
  --output local-output/thesis-en \
  --figure-profile dissertation
```

Der Auswahl-Exporter generiert die aktuellen Ergebnisabbildungen und -tabellen neu. Dreizehn frühere englische Abbildungen bleiben als feste Publikationsexporte mit ihren ursprünglichen Quellzuordnungen und Hashes erhalten. Sie werden mit folgendem Befehl kopiert und überprüft:

```
python3 scripts/dissertation/export_frozen_thesis_figures.py \
  --output local-output/thesis-en-fixed
```

Diese festgelegten Exporte bewahren die früheren Layouts. Durch das Kopieren werden die zugrunde liegenden Analysen nicht erneut ausgeführt. Konzeptionelle Diagramme stammen aus den mitgelieferten englischen draw.io-Quellen [30] und verwenden den Exporter unter `scripts/dissertation/drawio/`. Das LaTeX-Projekt enthält die endgültigen PDF-Abbildungen, Tabellen und Texte, die zum Erstellen des Dokuments benötigt werden. Die Neuberechnung von Qualitätsmetriken oder Energieintegralen erfordert die separaten Vorhersage- oder Wellenformdatensätze.

B.2.1 Überprüfung der gespeicherten numerischen Eingaben

Bei einer früheren Offline-Prüfung wurden 227 numerische Dateien und 38 Bestätigungsausgaben Byte für Byte aus ihren eingefrorenen Eingaben reproduziert [95]. Zudem wurden Modelloperatoren, Bewertungsgrößen und ausgewählte Vorhersageidentitäten überprüft. Gespeicherte Bootstrap-Werte wurden wiederverwendet; Inferenz, Qualitäts-Resampling und physikalische Erfassung wurden nicht wiederholt. Die aktuellen Auswahlexporte verfügen über eigene Eingabemanifeste und numerische Prüfungen. Diese Prüfungen ermitteln, welche aufgezeichneten Eingaben zu einem Ergebnis geführt haben. Die Reproduzierbarkeit auf Hardwareebene hängt zudem von den kompilierten Artefakten, den Laufzeitversionen und den Geräteeinstellungen ab.

B.3 Messprotokolle und Messumfang

Jede Konfiguration verknüpft die kompilierten Artefakte, die Laufzeitumgebung, die Qualitätsbewertung und die Durchsatzbeobachtungen. Durchsatzaufzeichnungen enthalten die Aufwärmphase, die Anzahl der abgeschlossenen Aufgaben und das gemessene

Intervall. Energieaufzeichnungen identifizieren zusätzlich den elektrischen Kanal, die Kalibrierung und das Integrationsintervall. Anhang C enthält die Einstellungen für die Ausführungskonfigurationen und Auswahl.

Der primäre Vergleich wendet die numerische 5%-Regel für den relativen Qualitätsverlust gegenüber der CPU-Referenz an und stützt sich dabei auf ungerundete Werte. Die beobachteten Wiederholungsbereiche beschreiben Abweichungen zwischen den Durchläufen. Sie berücksichtigen weder die Unsicherheit bei der Gewinnerauswahl noch alle systematischen Messeffekte. Da einige historische Aufzeichnungen zu Compilern, Auswertungsprogrammen und Gerätestatus unvollständig sind, kann das Archiv nicht jede frühere Ausführungsumgebung rekonstruieren.

Kalibrierung, separate Verifikation und Validierung unter realer Last werden in Kapitel 4 beschrieben. Die Bestätigung der beibehaltenen Hardware identifiziert den Kanal CH0 und den eingebauten ADS7953. Die Bezeichnung ADS7952 in einer Quelle ist ein Dokumentationsfehler. Aufbauspezifische Kalibrierungsprofile bewahren die auf die Energiebeobachtungen angewendeten Koeffizienten.

Abbildung B.1 ergänzt die in Abschnitt 4.3.3 zusammengefasste Prüfung der Stromkalibrierung. Sie zeigt die einzelnen Abweichungen von der Fluke-Referenz im unabhängigen Verifikationsdurchlauf.

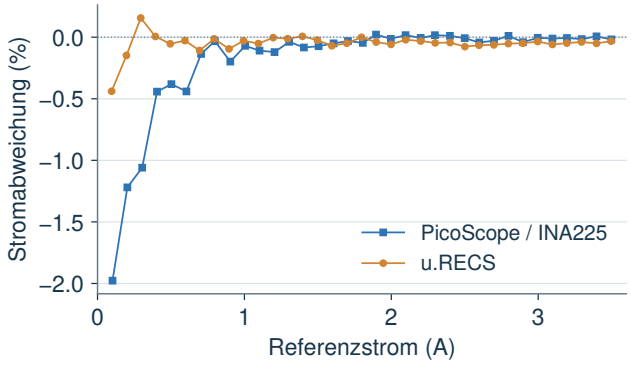


Abbildung B.1: Vorzeichenbehaftete Stromabweichungen von der Fluke-Referenz im separaten Durchlauf der Verifikation: 35 von Null verschiedene Werte pro Pfad, einschließlich der größeren Restabweichungen bei niedrigen Stromstärken. Neu gezeichnet aus den archivierten Verifikationszeilen [99].

B.4 Ergänzende Angaben zu den Energieexperimenten

Die folgenden Angaben ergänzen die experimentellen Untersuchungen in Abschnitt 4.2 und die Verifikation in Abschnitt 4.3.3. Sie gelten jeweils für die zugehörige Versuchsreihe.

Spannungsmodell der Referenzmessungen. Das Spannungsmodell aus Gleichung 4.9 wurde für Ströme zwischen 0 und 3,5 A charakterisiert. Die aus den dokumentierten Kalibrierungsmessungen übernommenen Koeffizienten betragen $a_U \approx 19{,}062\,607\,\mathrm{V}$ und $b_U \approx -0{,}074\,445\,82\,\mathrm{V/A}$ [97, 99]. Für Ströme außerhalb des untersuchten Bereichs wird das Modell linear extrapoliert. Die Vergleiche mit zwei Oszilloskopen verwenden dieses Spannungsmodell für beide Pfade und bewerten daher die Übereinstimmung der Strompfade. Andere Versuchsreihen verwenden ihre aufgezeichneten Spannungsmesswerte oder Schätzwerte. Der für die Spannungsmessung verwendete PicoScope-Eingang hat eine Bandbreite von 20 MHz [125].

Leistungsskalierung beim Messgeräte- und Dauervergleich. Die Untersuchung mit dem Jetson und der *u.RECS*-Messung verwendet den aufbauspezifischen Faktor

$$P_{\mathrm{Jetson,corr}} = c_{\mathrm{setup}} U_{\mathrm{est}} I_{\mathrm{cal}}, \qquad c_{\mathrm{setup}} \approx 0{,}97. \tag{B.1}$$

Der Faktor c_{setup} wurde aus den mittleren Abweichungen zur Referenz in den beiden Pilot-Benchmarks variables YOLO und GEMM-FP16 abgeleitet. Für die nachfolgenden Benchmark-Vergleiche blieb er unverändert [160, pp. 65–66]. Die Shelly-Messwerte werden mit ihrer empirisch ermittelten Skalierung ausgewertet. Diese Skalierung gleicht die unterschiedlichen elektrischen Messgrenzen der Messsteckdose und der Messung an der Modul- oder Beschleunigerversorgung nicht an.

Die Dauerstudie umfasst sieben Arbeitslasten bei zehn Dauerwerten von 5 bis 600 s mit jeweils 15 Wiederholungen pro Dauer. Sowohl die u.RECS-Messung als auch das PicoScope zeichnen mit 2 kS/s auf. Nach der Korrektur weichen die angegebenen Werte der mittleren Leistungsaufnahme für *u.RECS* um höchstens etwa 0,5% vom PicoScope-Referenzwert ab. Dies validiert die korrigierte Methode bei realen Arbeitslasten über die getesteten Laufzeiten hinweg [160, pp. 64–67].

Modelle, Rechenlasten und Datensatzbezeichnungen. Die FP16-Messungen mit langen Zeitfenstern bilden eine eigenständige Versuchsreihe. Die Jetson-Versuche zur Wiederholbarkeit bei unterschiedlichen Erfassungsraten verwenden GEMM und YOLO mit TensorRT in FP32, FP16 und INT8, YOLO mit variabler Aktivität sowie Gemma3-12B über Ollama [100, 113]. Gemma3-4B und Gemma3-12B werden aufgrund ihrer unterschiedlichen Modellgrößen getrennt ausgewertet. Für die Hailo-10-Messungen werden die in den Messdaten hinterlegten Bezeichnungen GEMM, YOLO, variable-YOLO und

LLM verwendet. Einige ältere Aufzeichnungen enthalten nur unvollständige Angaben zu Eingabedaten, Modellversionen und Kompilierungseinstellungen. Die Auswertung bezieht sich daher jeweils auf die dokumentierte Versuchsreihe. Geräteübergreifende Vergleiche mit festgelegten Modellen, Laufzeiteinstellungen und einer definierten Anzahl vollständig verarbeiteter Aufgaben werden in den Inferenzkapiteln behandelt [96, 99].

Wiederholbarkeit bei unterschiedlichen Erfassungsraten. Diese Untersuchung umfasst acht Jetson- und vier Hailo-Reihen mit insgesamt 323 Ratengruppen und 4 842 auswertbaren Ergebnissen. Eine Ratengruppe enthält die wiederholten Ausführungen derselben Berechnung bei einer festgelegten Erfassungsrate. Tabelle B.2 unterscheidet die Streuung innerhalb dieser Gruppen von den Unterschieden zwischen den Gruppen.

Der Variationskoeffizient (*coefficient of variation*, CV) setzt die Populationsstandardabweichung der gemessenen Energien ins Verhältnis zu ihrem Mittelwert und wird in Prozent angegeben. Für den Vergleich zwischen den Raten wird zunächst der gleichgewichtete Mittelwert aller Ratengruppenmittelwerte gebildet. Die Verschiebung bezeichnet die relative Abweichung eines Gruppenmittelwerts von diesem Vergleichswert. Angegeben werden jeweils der größte CV und die betragsmäßig größte Verschiebung innerhalb einer Versuchsreihe.

Tabelle B.2: Größter Variationskoeffizient der Energie innerhalb einer Erfassungsrate und größte absolute relative Abweichung eines Ratengruppenmittelwerts vom gleichgewichteten Mittel aller Ratengruppen. Die Anzahl der Durchläufe umfasst nur Aufzeichnungen mit einem auswertbaren Lastintervall [96].

Plattform	Arbeitslast	Raten	Durchläufe	Max. CV (%)	Max. Verschiebung (%)
Jetson	GEMM-FP32	27	405	0,37	0,40
Jetson	GEMM-FP16	27	405	0,73	2,08
Jetson	GEMM-INT8	27	405	0,63	1,69
Jetson	YOLO-FP32	26	390	0,41	0,89
Jetson	YOLO-FP16	27	405	0,44	0,25
Jetson	YOLO-INT8	27	405	0,73	0,31
Jetson	Variables YOLO	27	405	0,49	0,56
Jetson	Gemma3-12B	27	405	0,58	1,66
Hailo	GEMM	27	405	0,68	1,48
Hailo	YOLO	27	405	1,01	1,20
Hailo	Variables YOLO	27	405	9,45	6,74
Hailo	LLM	27	402	46,06	24,30

Kontrollversuch zum Einfluss der Erfassungsrate. Der Kontrollversuch verwendet zwölf FP16-Ausführungen mit derselben TensorRT-Engine, jeweils 250 abgeschlossenen Inferenzen, unveränderter *Spin-Wait*-Einstellung und einer Pause von 120 Sekunden zwischen Prozessende und nächstem Start. Für $A = 2$ kS/s und $B = 5$ MS/s werden in zwei Messsitzungen die Reihenfolgen ABBAAB und BAABBA verwendet. Damit kommt jede Rate über beide Sitzungen hinweg an jeder Position einmal vor.

Ein additives lineares Modell berücksichtigt die Erfassungsrate, die Messsitzung und die Position innerhalb der Reihenfolge. Die Position wird als kategoriale Variable behandelt. Die Modellmatrix besitzt acht linear unabhängige Spalten. Bei zwölf Beobachtungen verbleiben damit vier Restfreiheitsgrade für die Schätzung der nicht durch das Modell erklärten Streuung. Das Modell setzt additive Sitzungsunterschiede und gemeinsame Positionseffekte voraus. Wechselwirkungen zwischen diesen Einflussgrößen werden nicht geschätzt.

Die zweiseitigen 95%-Konfidenzintervalle werden mit der t-Verteilung und vier Restfreiheitsgraden berechnet. Die geschätzten Änderungen von 5 MS/s gegenüber 2 kS/s sowie die Intervallgrenzen werden durch den beobachteten Mittelwert bei 2 kS/s geteilt und in Prozent angegeben. Die Intervalle gelten unter den Modellannahmen für diese zwölf Durchläufe. Sie stellen weder einen formalen Äquivalenztest noch einen Nachweis der absoluten Messgenauigkeit dar [99, 101].

Die als „Hailo LLM“ aufgezeichnete Reihe erreicht einen maximalen Energie-CV von etwa 46 % und eine größte Gruppenabweichung von etwa 24 %. Drei von 405 Aufzeichnungen liefern kein auswertbares Lastintervall. Variables Hailo-YOLO erreicht einen maximalen CV von 9,45 %, während die kontinuierlichen GEMM- und YOLO-Ausführungen deutlich weniger streuen. Aufgrund der oben beschriebenen Lücken in den Modell- und Kompilierungsaufzeichnungen lässt sich das beobachtete Verhalten der Hailo-LLM-Reihe nicht eindeutig einer konkreten Modellarchitektur zuordnen [96, 99].

Prüfung der automatischen Intervallerkennung. Die angeforderte Dauer und die resultierende Energie beeinflussen den Schwellenwert nicht. Die relativen Schwellen 0,4 und 0,6 prüfen die Empfindlichkeit gegenüber der primären 0,5-Regel. Wird kein Intervall erkannt, bleibt das Ergebnis fehlend. Die archivierte Methodenbeschreibung enthält alle Erkennungsbedingungen und den Umgang mit Endzeitstempeln [99].

Für die Untersuchung wechselnder Aktivität auf Hailo wird das explizit aufgezeichnete Intervall einschließlich des zusätzlichen Randbereichs verwendet. Die Aufzeichnungen tragen die Bezeichnung `variable-YOLO`. Das anhaltende Anfangsniveau erlaubt hier keine zuverlässige Erkennung des Lastbeginns. Diese Intervallwahl gilt für alle zugehörigen Raten- und Dauerreihen. Ihr Einfluss auf den Vergleich von mittlerer

Leistungsaufnahme und Energie wird in Abschnitt 4.3.3 anhand der unterschiedlich langen Messintervalle erläutert [99, 101].

Sensitivitätsprüfung der Rekonstruktion. Eine zusätzliche Prüfung reduziert die Daten vor der Rekonstruktion auf 1 MS/s. Dabei bleibt das Integral der vollständigen Aufzeichnung erhalten, einige anschließend berechnete Integrale mit niedriger Abtastrate ändern sich jedoch. Die Hauptergebnisse verwenden deshalb die ursprünglichen Daten mit 5 MS/s. Der alternative Weg dient als dokumentierte Sensitivitätsprüfung [99].

Segmentierung bei der Spektralschätzung. Für den Vergleich von Energieintegration und spektraler Abdeckung bei langen Messintervallen werden aus allen 15 FP16-Aufzeichnungen aufeinander abgestimmte viersekündige Aktiv- und Leerlaufintervalle mit 1 MS/s ausgewertet. Einsekündige Hann-Segmente mit 50% Überlappung ergeben jeweils sieben Segmente. Diese Vorverarbeitung ist von der Energierekonstruktion der Originalkurve getrennt [99, 101]. Bei der Spektralanalyse auf Hailo verwendet die Schätzung Hann-Segmente mit 1 048 576 Abtastwerten, 50% Überlappung und die dokumentierte Umrechnung in Leistung. Die Frequenzperzentile werden für jede Aufzeichnung einzeln berechnet und anschließend aggregiert [101].

Offset-Korrektur beim Vergleich der Oszilloskope. Die Aufzeichnungen zur Objekterkennung in FP32 (Datensatzbezeichnung `YOLO-FP32`) verwenden eine separate additive Korrektur des Tektronix-Stromoffsets. Die Rohwerte und der Korrekturdatensatz bleiben erhalten. Diese Korrektur nutzt Informationen aus dem anderen Messpfad. Die daraus resultierende Übereinstimmung unterscheidet sich daher von einer unabhängigen Verifikation [99].

Die Wahl des Messverfahrens richtet sich danach, ob die Gesamtenergie einer Ausführung oder einzelne schnelle Leistungsschwankungen untersucht werden sollen. Tabelle B.3 ordnet diesen Fragestellungen geeignete Messpfade und die erforderlichen Prüfungen zu.

B.5 Kalibrierung des Systemeingangs und aufgezeichneter Messbereich

Der Einsatzvergleich gibt die Energie am Eingang jedes bestückten Systems an, einschließlich des Leerlaufverbrauchs und nachgelagerter Umwandlungsverluste. Die Kalibrierungsdatensätze identifizieren CH0 und die Verbindung `9V_20V_IN_after_R16_to_GND`. Für H8, H10 und DeepX gelten separate Profile (Tabelle B.4). Ihre

Tabelle B.3: Messoptionen für die in Kapitel 4 untersuchten Fragestellungen. Numerische Ergebnisse behalten ihre getestete Arbeitslast, ihre Messgrenzen und ihr Intervall bei.

Frage	Nützliche Beobachtung	Erforderliche Überprüfung
Energie im Ausführungsintervall	Kalibrierter DC-Eingang des vollständigen Knotens	Abgeschlossene Arbeiten, ursprüngliche Trace-Kontinuität, übereinstimmender Start- und Endzeitpunkt und Kanal-Verifikation
Energie über ein kurzes Ereignis	Externe DC-Referenz mit hoher Rate, gefolgt von einer Ratenrekonstruktion	Fehler bei der vorgesehenen Dauer und den Gitter-Offsets. Das 1%-Persistenzminimum für Jetson bei 100 ms beträgt 80 kS/s
Schnelle Leistungsschwankungen	Externe Erfassung mit hoher Rate	Gemessene spektrale Abdeckung und analoge Antwort. Die FP16-Entscheidungen zur 95/99%-Abdeckung liegen bei 125/160 kS/s
Überwachung zugänglicher Module/Karten	Eingebettete DC-Messung oder validierte Telemetrie	Elektrische Messgrenze an der Versorgungsschiene, tatsächliches Aktualisierungsverhalten und paarweise Übereinstimmung für das beabsichtigte Aktivitätsmuster
Aus der Stromversorgung entnommene Energie	AC-seitige Messung der angegebenen Anordnung	Enthaltene Lasten, Umwandlungsverluste, das tatsächliche Intervall und etwaige empirische Skalierungen

Quelldatensätze werden unter `results/energy-measurement/data/calibration/split-setups/` [96, 97] gespeichert.

Tabelle B.4: Aufbauspezifische Leistungs-/Energiefaktoren, erfasst am 4. September 2026. Jeder Faktor wird einmal nach den Strom- und Spannungskorrekturen angewendet.

Einrichtung	Faktor s
Hailo-8	0,913 634
Hailo-10H	0,896 397
DeepX DX-M1	0,903 508

Der H10-Datensatz verwendet eine Erfassungsrate von 2 kS/s und 30-Sekunden-Aufnahmen. Seine beiden hinzugefügten Lasten wiesen gemessene Strom-Spannungs-Paare von 0,509 A/18,55 V und 1,01 A/18,29 V auf. Benachbarte Leerlaufbeobachtungen eliminieren die Dauerlast bei der Anpassung der inkrementellen Leistungsaufnahme. Dies dient der Überprüfung der lastabhängigen Skalierung. Es handelt sich nicht um ei-

ne unabhängige Messung des absoluten Offsets des gesamten Systems. Die Validierung des ursprünglichen Spannungsmodells ist in Abschnitt 4.3.3 beschrieben.

Bei den Split-System-Messungen kombiniert die beibehaltene Berechnung die Stromkorrektur, das Spannungsmodell und die aufbau-spezifische Leistungsskalierung wie folgt:

$$\begin{aligned} I &= g\left(\frac{r}{1000} + o\right), \\ U &= a_U + b_U I, \\ P &= c_{\text{setup}}\, s\, I\, U. \end{aligned} \tag{B.2}$$

Hier ist r der aufgezeichnete Wert in der Milliampere-Konvention, o der Offset in Ampere und g der Verstärkungsfaktor für die Stromkorrektur. Der Faktor s skaliert die Leistungsaufnahme oder Energie nach den Strom- und Spannungskorrekturen. Tabelle B.4 enthält diese Profilfaktoren. Im historischen Pfad wird s einmalig nach der trapezförmigen Integration angewendet. Bei den Bestätigungsmessungen wird er einmal auf die Leistungsaufnahme angewendet, bevor über das angepasste Ausführungsintervall abtastzentrierte konstante Intervalle integriert werden. Beide Verfahren dividieren durch die Anzahl der abgeschlossenen Inferenzschritte aus derselben Erfassung [97].

Die drei Einrichtungsprofile behalten ihre Referenzmessungen vom September bei und wurden sowohl in den ausgewählten historischen Aufzeichnungen als auch in der Bestätigungsstudie verwendet. Das H10-Profil weist zwei Warnungen auf: $s < 0{,}9$ und eine Streuung von 2,026% zwischen seinen punktweisen Skalierungsfaktoren. Diese Streuung liegt knapp über dem aufgezeichneten Warnschwellenwert von 2%. Sie beschreibt die Konsistenz seiner beiden Kalibrierungspunkte [97].

Die Bestätigungsangabe des Bedieners identifiziert CH0 und den eingebauten ADS7953 und klärt damit die Bezeichnung ADS7952 in einer historischen Quelle. Die Kanalparameter stimmen über 70 primäre Bestätigungsaufzeichnungen, zwei ergänzende Aufzeichnungen und 42 ausgewählte frühere Wiederholungen hinweg überein. Das dokumentierte Design verwendet einen 20-mΩ-Shunt, einen INA225 mit Verstärkung 25 und einen 12-Bit-, 2,048-V-ADC-Messbereich, was 1 mA/Zählwert und einer nominalen 4,096-A-Vollaussteuerungsgrenze entspricht. Der unabhängige Lastdurchlauf umfasst 0–3,5 A. Diese Auslegungs- und Kalibrierungsbereiche geben nicht den analogen Headroom jedes einzelnen Durchlaufs wieder. Die zugehörige Laborreferenz verwendet einen TCP0030A im 5-A-Bereich bei einer gleichzeitigen Erfassungsrate von 5 MS/s. Seine vollständige nominelle Übertragungsantwort von 77 kHz wurde nicht unabhängig verifiziert. Die 225 Ersatz-DeepX-Ausführungsintervalle behalten eine Erfassungsrate von 2 kS/s bei, ohne dass in ihren Manifesten Abtastwerte verloren gehen.

Für alle drei Konfigurationen liegen am Gesamtsystem-Eingang abgeglichene M.2-Ein-/Aus-Beobachtungen vor. Sie messen die zusätzliche Leerlauflast des angeschlossenen Beschleunigers und versetzen diesen anschließend wieder in den Ein-Zustand. Die primären Einsatzergebnisse verwenden den gemessenen Gesamtsystemwert ohne diesen Abzug. Sie beschreiben daher die bestückten Testsysteme und nicht eine geschätzte Maschine, die ausschließlich aus GPU besteht. Die Ein-/Aus-Beobachtungen rekonstruieren nicht den Schaltzustand jedes früheren GPU-Full-Messlaufs.

Detaillierte Verbraucherverkabelung, historische Einstellungen des aktiven Bereichs und eine unabhängige Überprüfung des absoluten Offsets sind nicht für jede Erfassung verfügbar. Zudem wird das ursprüngliche Spannungsmodell in den Einrichtungsprotokollen nicht für jeden Host erneut unabhängig validiert. Die Referenzversuche in Kapitel 4 etablieren die Methode innerhalb der angegebenen elektrischen Pfade. Ihre empirischen Fehler stellen keine universelle Unsicherheitsgrenze für alle Systemenergien dar. Eine reine GPU-Konfiguration oder eine andere Versorgungsanordnung erfordert eine eigene Beobachtung der Systemeingänge.

B.6 Prüfungen im Dauerbetrieb und zur Eingabe-Ausgabe-Zuordnung

Im Rahmen des begleitenden Experiments vom 18. bis 19. Oktober 2026 wurden vierzehn Konfigurationen getestet: sieben zu diesem Zeitpunkt ausgewählte Native-Split-Konfigurationen und deren Full-Referenzen [97]. Zunächst wurde die Zuordnung von Eingabe zu Ausgabe unter produktiver Parallelität anhand von mindestens 32 unterscheidbaren Eingaben überprüft. Anschließend erzeugten fünf randomisierte Blöcke mit neuen Prozessen 70 Durchsatzbeobachtungen. Jeder Prozess benötigte 30 s für die Aufwärmphase und die Entleerung, gefolgt von 60 s für die Aufgabenannahme und einer abschließenden Entleerung. Die Zählwerte und Zeitangaben beziehen sich auf abgeschlossene Aufgaben innerhalb desselben Zeitraums.

Dieses Experiment behält sechs schnellere Splits und drei energieeffizientere Splits für seine festen Konfigurationen bei. Sein YOLO11l-Split ist H10 b120, nicht der in der abgeschlossenen Kampagne ausgewählte „Generic DeepX b511“. Es unterstützt somit das Verhalten der getesteten Implementierungen, ohne die Einsatzvergleiche der Kampagne zu ersetzen.

Der Energieprotokollsatz enthält 68 Primärintegrationen und zwei spätere Ergänzungen, jeweils mit eigener Dauer und Anzahl der abgeschlossenen Arbeitsschritte. Durch die Beschränkung des Vergleichs auf die 26 von 35 Paaren, die in derselben Sitzung erfasst wurden, bleiben alle sieben Energierichtungen erhalten. Die beiden ergänzenden Energiedurchläufe stellen die Sensorabdeckung für die früheren Durchsatzmessläufe

nicht wieder her. Direkte Qualitätsvergleiche stützen sich auf Vorhersagen zu 5 000 gemeinsamen Bildidentitäten und 1 000 gepaarten Neuabtastungen. Die detaillierten Blöcke, Intervalle und Sitzungszuordnungen verbleiben im zitierten numerischen Archiv und werden nicht als Unsicherheitsschätzungen für neu ausgewählte Gewinner herangezogen.

C Details zur Reproduktion der Split-Inferenz

Dieser Anhang enthält die Einstellungen, die zur Interpretation und Reproduktion der Split-Inferenz-Analysen erforderlich sind. Anhang B ordnet die numerischen Eingaben den Reproduktionsbefehlen zu. Die Ergebnisse zum Einsatzvergleich, zur Auswahl des Ausführungsmoduls und zur Auswahl des Graphen basieren auf der unten beschriebenen gemeinsamen Kampagne.

C.1 Aufzeichnungen zur Experimentkonfiguration und -durchführung

Tabelle C.1 fasst die erfassten Plattformbeobachtungen, die installierte Software und die Ausführungseinstellungen für die drei Konfigurationen zusammen. Die Softwarebestandsaufnahme erfolgte am 18. Oktober 2026. Die Beobachtungen zu Leistungsprofil, Taktfrequenz und PCIe stammen aus den aufgezeichneten YOLOv7-Plattformprüfungen. Kompilierte Artefakte behalten ihre eigene Identität. Eine installierte Compiler-Version wird nicht herangezogen, um die Version abzuleiten, mit der jedes Artefakt ursprünglich erstellt wurde [96, 97].

Die Softwarebestandsaufnahme wird in der Datei `inputs/metrology/version_and_precision_bindings.json` im Bestätigungsarchiv gespeichert. Plattformbeobachtungen sind im YOLOv7-Quellbericht enthalten, und die Ausführungseinstellungen liegen den Messprotokollen bei. Die Felder „Trägerrevision“, „Live-Lüfterdrehzahl“ und „ursprüngliche Build-Version“ werden nicht für jede Konfiguration erfasst. Diese Lücken werden getrennt von den gemessenen Durchsatz-, Qualitäts- und Energiewerten geführt.

C.1.1 Konfigurations- und Ausgabedatensätze

Modelldatensätze identifizieren den Graphen, die Eingabe- und Ausgabetensoren, die Klassenabbildung sowie die kompilierten Artefakte. Der Messplan erfasst die Kandidatenauswahl, die Vorverarbeitung, den Abschluss einer Inferenzaufgabe, Wiederholungen und Energieeinstellungen. Die Kalibrierungsbilder sind von den Validierungsbildern getrennt, die zur Messung der Ergebnisqualität verwendet werden. Die Exporte pro Durchlauf speichern die Anzahl der abgeschlossenen Aufgaben und die Zeitfenster, während das Berichtsmanifest die Ergebniszeilen mit ihren Laufzeiteinstellungen und der Kalibrierung verknüpft.

Tabelle C.1: Aufgezeichnete Einrichtungs- und Laufzeiteinstellungen. Gemeinsame Zeilen gelten für alle drei Hosts; Anforderungs- und Worker-Limits beschreiben Generic. Takt- und Verbindungswerte sind Plattformbeobachtungen und keine kontinuierlichen Aufzeichnungen jedes Durchlaufs.

Einstellung	H8	H10	DeepX
Host	Jetson Orin NX, 16 GB		
L4T / TensorRT	36.4.7 / 10.3.0.30		
Beobachtetes Profil	`MAXN_SUPER`		
Beobachtete CPU / GPU	1984 / 1173 MHz		
Beobachtete PCIe-Verbindung	8,0 GT/s, ×4		
Beschleuniger	Hailo-8	Hailo-10H	DX-M1
Installierte Laufzeitumgebung	HailoRT 4.20.0	HailoRT 5.3.0	DX-RT 3.3.2
Firmware-Snapshot	4.20.0	5.3.0	2.5.6
Installierter Compiler	DFC 3.33.1	DFC 5.3.0	DX-COM 2.3.0
Generic-Anfragen	1	8	4
Worker / Warteschlange	2 Worker / Warteschlangenlimit 2		
Batch / Wiederholungen	1 / 3 unabhängige Prozesse		
Aufwärmphase / Aufgaben	100 abgearbeitet / 1 000 pro Wiederholung		
Energielast	60 s Aufgabenannahme und Entleerung, drei Wiederholungen		

Die Detektoradapter verarbeiten ankerbasierte Multiskalen-Heads, dekodierte Detektionen und DFL-Roh-Heads. Sie wenden die vom kompilierten Modell geforderte Dekodierung und Unterdrückung an, bevor sie das fertige Ergebnis ausgeben. Kapitel 7 beschreibt diese Abläufe. Separate Überprüfungen bei identischen Eingaben vergleichen die Ausgaben des Ausführungsmoduls mit den Full-ONNX-Vorhersagen. Deren Übereinstimmungsstatistiken stellen keine AP auf Datensatzebene dar.

C.2 Einstellungen für Ausführung und Qualitätsbewertung

Die Qualität wird anhand von 5 000 Validierungsbeispielen pro Aufgabe gemessen. Eine Konfiguration wird zugelassen, wenn ihr relativer Qualitätsverlust gegenüber der CPU-ONNX-Referenz höchstens 5% beträgt. Die aktuellen Zusammenfassungen des Runner-

Vergleichs berichten Punktwerte. Archivierte Intervalle beschreiben Abweichungen gegenüber der CPU-Referenz und keine direkten „Split-minus-Full“-Unterschiede [98].

Detektorauswertung. Die Qualität wird anhand abgeschlossener Erkennungsdatensätze bewertet. Die beibehaltene `accuracy_reporting_v1`-Richtlinie verwendet den kanonischen COCO-Bounding-Box-Evaluator aus `pycocotools`. Er verwendet zehn IoU-Schwellenwerte von 0,50 bis 0.95, 101 Recall-Positionen, die Zusammenfassung über alle Objektgrößen sowie bis zu 100 Erkennungen pro Bild und Kategorie für den AP. Die optimierte Implementierung nutzt die offiziellen Abgleichergebnisse während des Bootstrap-Resamplings [16, 96] wieder.

Die Erkennungspipeline erzeugt zunächst Begrenzungsrahmen, Bewertungen und Klassen für das Originalbild. Die festgelegte Richtlinie sieht einen Konfidenzschwellenwert von 0,25 und eine Ausgabebegrenzung von 300 Erkennungen vor, einschließlich des entsprechenden CPU-Referenzpfads. Der Auswerter wendet anschließend seine eigene Begrenzung von 100 Erkennungen pro Bild und Kategorie an. Diese Begrenzungen greifen in unterschiedlichen Phasen. AP beschreibt daher die vollständigen Ergebnisse der Ausführungskonfigurationen gemäß der festgelegten Dekodierungsrichtlinie. Sofern eine Host-NMS erforderlich ist, erfolgt sie klassenabhängig mit einem IoU-Schwellenwert von 0.45. Integrierte YOLO26-Ausgaben behalten ihre graphdefinierte Verarbeitung bei, ohne dass ein zweiter NMS-Durchlauf erforderlich ist.

Die separate B500-Compiler-Prüfung in Abschnitt C.5 verwendet eine frühere interne Metrik und liefert keine AP-Werte für den Hauptvergleich. Veröffentlichte Ergebniszeilen behalten die gemeldete Metrik und die Anzahl der Stichproben bei. Das abgeflachte Archiv rekonstruiert nicht jede frühere Version des Evaluator-Pakets. Die beibehaltenen Richtlinienaufzeichnungen und der aktuelle Evaluator-Quellcode liefern die oben genannten detaillierten Einstellungen.

Zeit und Energie. Der Durchsatz wird in drei unabhängigen Prozessen mit jeweils 1 000 gemessenen Aufgaben ermittelt. Die überprüften Laufzeitprotokolle geben 100 Aufwärmaufgaben und eine vollständige Entleerung vor der Zeitmessung an. Die Messung umfasst das Befüllen der Pipeline, erforderliche Kopien, den Abschluss einer Inferenzaufgabe und die Entleerung. Die Energieerfassung erfordert 60 s Arbeitszeit und entleert anschließend die angenommenen Aufgaben, bevor das Ende gemeldet wird. Die Energie pro Bild entspricht dem arithmetischen Mittel aus drei kalibrierten E_r / N_r-Beobachtungen. Durchsatz und Energie werden für dieselbe Konfiguration separat erfasst.

DeepX Native verwendet Batch eins, eine Engine und höchstens vier ausstehende asynchrone Beschleunigeranfragen. Separate Ausgabepufferplätze erhalten die Zuordnung zu den jeweiligen Anfragen. Die Split-Ausführung nutzt ein FIFO der Tiefe drei und einen seriellen TensorRT-Konsumenten. Andere Implementierungen verwenden ihre aufgezeichneten Zeitpläne. Der Vergleich bewertet vollständige Ausführungskonfigurationen mit ihren jeweiligen Parallelitätseinstellungen.

Das Abschlusskriterium für die Zeitmessung umfasst die für die Klassifikation oder Erkennung erforderliche Ausgabeverarbeitung. Ein unabhängiges Korrektheitsorakel kann außerhalb der Zeitmessung ausgeführt werden, während alle zur Erledigung der Aufgabe erforderlichen Arbeitsschritte im gemessenen Pfad verbleiben. Die Aufzeichnungen zum Abschlusskriterium erfassen die tatsächlichen Modi für Dekodierung, NMS, integrierte Ausgabe und Materialisierung. Übereinstimmende Abschlusskriterien der Aufgaben bedeuten nicht zwangsläufig identische Operationen oder gleiche Ergebnisqualität.

Der Einsatzvergleich umfasst 451 Ausführungskonfigurationen: 204 Native-Splits, 205 Generic-Splits und 42 Full-Alternativen. Nach Anwendung des Fünf-Prozent-Filters verbleiben 408 Konfigurationen: 187 Native-Splits, 188 Generic-Splits und 33 Full-Alternativen. Energieangaben liegen für 450 Konfigurationen vor. Die Generic-YOLOv7/H8-b009-Beobachtung enthält Durchsatz- und Qualitätswerte, jedoch keinen Energiewert. Bei der Auswahl werden ungerundete Qualitäts- und Durchsatzwerte verwendet. Jeder Nenner bezieht sich auf eine spezifische Full-Konfiguration. Diese wird nicht durch eine über die Hosts gemittelte TensorRT-Zusammenfassung ersetzt. Verhältnisse, Energiewerte und Qualitätsangaben bleiben mit dieser Konfiguration verknüpft.

C.3 Kandidatenmengen und Auswahlbudgets

Der gepaarte Vergleich umfasst 204 Schnitte, die von beiden Ausführungsmodulen unterstützt werden. Bei Anwendung der 5%-Regel für den relativen Qualitätsverlust verbleiben 187 Paare in allen 21 Modell-Beschleuniger-Kombinationen: 151 Klassifikatorpaare in neun Kombinationen und 36 Detektorpaare in zwölf. Bei den 17 ausgeschlossenen Paaren handelt es sich um MobileNet-Schnitte auf H8 oder H10, deren Generic- und Native-Qualität beide die Regel nicht erfüllen. Jede Rangfolge wird anhand derselben zulässigen Kandidaten innerhalb einer Kombination bewertet.

Generic verwendet das oben beschriebene Durchsatzprotokoll mit zwei Pipeline-Workern und einer Warteschlange der Tiefe zwei. H10 erlaubt acht ausstehende Beschleunigeranfragen und DeepX erlaubt vier. Der H8-Produzent nutzt HailoRT VStreams

und führt seine Arbeit überlappend mit dem TensorRT-Konsumenten aus. Die gemessene Aufgabe umfasst die TensorRT-Ausführung, erforderliche Kopiervorgänge und die Ausgabeverarbeitung.

Ein Budget von k erlaubt höchstens k Tests pro Kombination. Sind weniger Kandidaten verfügbar, werden alle getestet. Bei einer Vorauswahl wird das schnellste gemessene Ergebnis beibehalten und mit dem schnellsten zulässigen Schnitt für dasselbe Ausführungsmodul und dieselbe Kombination verglichen. Alle Kombinationen werden gleich gewichtet. Die Auswahl erfolgt anhand ungerundeter Mediane des Durchsatzes. Ein Schnitt, der das gemessene Maximum erreicht, gilt als exakter Treffer. Die Trefferzahlen beschreiben die getesteten Kombinationen, nicht die Erfolgswahrscheinlichkeit für ein unbekanntes Modell.

Die anhand der gepaarten Daten angepassten Graphscores verwenden den Native-Durchsatz. Ihre Gewichte bleiben unverändert, wenn dieselben Vorauswahlen mit Generic ausgewertet werden. Für jeden „Model-Held-Out“-Fold erfolgt die Anpassung anhand der anderen sechs Modelle; das Testmodell wird auf allen drei Beschleunigern ausgeschlossen. Die gepaarten Detektorkombinationen enthalten jeweils drei Schnitte, sodass das Testen aller drei keinen Verlust bei den Vorauswahlen verursacht. Kapitel 6 definiert den Score und das Anpassungsziel.

Der umfassendere Generic-Vergleich wählt zwanzig Schnitte pro Modell und Beschleuniger aus, was 420 Konfigurationen ergibt. Graphfenster verteilen die Kandidaten entlang des Modells. Innerhalb jedes Fensters werden kleinere unterstützte Grenzen bevorzugt, wobei feste Regeln für Gleichstand, Abstand und Auffüllung gelten. Es handelt sich hierbei nicht um eine gleichmäßige Zufallsstichprobe aller möglichen Schnitte. Von diesen Kandidaten weisen 359 Durchsatzbeobachtungen auf. Compilerfehler und nicht unterstützte Grenzen machen die übrigen 61 aus. Die Qualitätsregel behält 331 gemessene Schnitte bei, bestehend aus 160 Klassifikator- und 171 Detektorkandidaten. Jede der 21 Kombinationen enthält zwischen sieben und zwanzig zulässige Schnitte. Dieser Vergleich umfasst Multi-Tensor-Grenzen, fügt jedoch keine Native-Messungen mit mehreren Eingängen hinzu.

Für diesen umfassenderen Satz werden die Gewichte an den Generic-Durchsatz angepasst. Gemeinsame, aufgabenspezifische, beschleunigerspezifische und kombinierte Anpassungen schließen jeweils das Testmodell auf jedem Beschleuniger aus. Die Merkmalsnormalisierung nutzt den vollständigen Kandidatengraphen vor der Messung und der Qualitätsfilterung, ohne den zurückgehaltenen Durchsatz zu verwenden. Das primäre Ziel besteht darin, die Verluste bei den Budgets eins, drei und fünf zu mitteln, wobei jedes Budget und jede Trainingskombination gleich gewichtet wird. Abschnitt 6.4.4 enthält die Such- und Gleichstandsregeln.

Die vollständige Auswahlsequenz wird anhand der gepaarten Schnitte ausgewertet. Die Grenztensorgröße liefert bis zu k Kandidaten für Generic-Tests. Native testet anschließend die beiden schnellsten Generic-Kandidaten und bestimmt die endgültige Auswahl. Die Auswertung gibt auch die Variante mit nur einem Native-Test an. Bei $k = 5$ erzielen 81 Generic-Tests und 42 Native-Tests denselben mittleren Native-Durchsatz wie 81 direkte Native-Tests auf denselben Graphen-Vorauswahlen. Bei $k = 12$ verwendet die stufenweise Abfolge 137 Generic- und 42 Native-Tests. Hierbei handelt es sich um Anzahlen von Messungen. Kompilierung, Qualitätsbewertung und Anpassung fallen nicht unter diese Budgets, sodass diese Anzahlen keine Reduzierung der gesamten Suchkosten belegen.

Abschnitt B.2 enthält die Befehle zur Reproduktion. Das Repository speichert die individuellen Rangfolgen der Kandidaten, die Gewichte der Kreuzvalidierungs-Folds und die Budgetergebnisse.

C.3.1 Angepasste Gewichte und Sensitivität

Die Generic-Variante mit gemeinsamen Gewichten und Modellausschluss wählt für jedes Testmodell einen separaten Gewichtsvektor aus (Tabelle C.2). Die Anpassung anhand aller Daten ergibt $(0.215, 0.035, 0.750)$. Dieser Vektor beschreibt den gemessenen Datensatz und wird nicht zur Darstellung der Leistung auf dem zurückgehaltenen Datensatz verwendet.

Tabelle C.2: Gemeinsame Generic-Graphscore-Gewichte mit Modellausschluss. Jede Zeile verwendet die anderen sechs Modelle für die Anpassung.

Ausgeschlossenes Modell	w_{comm}	w_{imb}	w_{ten}
MobileNetV3-L	0,227 5	0,115 0	0,657 5
RegNet-X	0,022 5	0,155 0	0,822 5
ResNet-50	0,202 5	0,005 0	0,792 5
YOLO11l	0,207 5	0,032 5	0,760 0
YOLO26m	0,215 0	0,035 0	0,750 0
YOLO26s	0,217 5	0,035 0	0,747 5
YOLOv7	0,600 0	0,100 0	0,300 0

„Bytes“ ist ein Kandidat bei der Gewichtsuche. Der ausgewählte Vektor darf daher auf dem durchsuchten Raster keinen höheren mittleren Verlust beim Training aufweisen als „Bytes“. Alle 56 primären Anpassungen erfüllen diese Prüfung. Dies bedeutet nicht, dass das ausgeschlossene Modell oder jedes einzelne Testbudget einen geringeren Verlust aufweist.

Tabelle C.3 untersucht das Trainingsziel, die Gitterauflösung, die Gleichstandsregel und die Behandlung der zugehörigen YOLO26-Modelle. Die Optimierung ausschließlich des Fünf-Test-Budgets reduziert den Verlust der kombinierten Anpassung von 9,80% auf 6,28%, verglichen mit 6,61% bei Bytes. Dieses alternative Ziel steht unabhängig vom primären Vergleich. Werden YOLO26m und YOLO26s gemeinsam ausgeklammert, steigt der Verlust der gemeinsamen Anpassung auf 16,17%, während die spezifischen Ergebnisse für den Beschleuniger und die kombinierten Ergebnisse unverändert bleiben. Der Transfer zwischen verwandten Modellen kann daher die gemeinsame Anpassung beeinflussen.

Tabelle C.3: Generic-Durchsatzverlust (%) bei fünf Tests unter alternativen Anpassungsoptionen. „Kombiniert“ bedeutet eine Anpassung sowohl nach Aufgabe als auch nach Beschleuniger. Der Wert für Bytes bleibt bei 6,61%.

Anpassungsoption	Gemeinsam	Kombiniert
Primär	10,52	9,80
Zielfunktion für fünf Tests	8,37	6,28
Gitterschritt 0,005	10,52	9,80
YOLO26-Modelle, die gemeinsam zurückgehalten wurden	16,17	9,80
Die Grenztensorgröße entscheidet bei Punktgleichheit	10,52	9,91

C.4 Statische Schätzung des Rechenaufwands

Der nachstehende Katalog erfasst die in den Entwicklungsstudien verwendeten historischen arithmetischen Proxies. Bei gewöhnlicher Faltung und Matrixmultiplikation wird gemäß den aufgeführten Konventionen eine Proxy-Einheit pro Multiplikations-Akkumulations-Schritt verwendet. Dies unterscheidet sich von der Berichtskonvention, die dem Zwei-Operationen-Modell entspricht, wie in Kapitel 5 beschrieben. Der Katalog enthält keine exakten Anzahlen arithmetischer Operationen für jeden Operator. Operatoren, denen Proxy-Kosten von Null zugewiesen wurden, können während der Ausführung dennoch Speicher-, Ablaufsteuerungs- oder Konvertierungskosten verursachen.

ConvTranspose verwendet den dichten, ausgangsbasierten Faltungsausdruck erneut. Hierbei handelt es sich nicht um eine allgemeine MAC-Anzahl für transponierte Faltung. Bei einem Eingangs- und einem Ausgangskanal, einem 2×2-Eingang, einem 2×2-Kernel, einem Stride von zwei sowie ohne Padding oder Bias ergibt die direkte Auswertung 16 Produkte in einem 4×4-Ausgang. Der beibehaltene Ausdruck liefert stattdessen 64 Proxy-Einheiten.

Im Rahmen einer anschließenden Offline-Prüfung wurden sieben vollständige ONNX-Graphen untersucht, die anhand von SHA-256 identifiziert wurden und insgesamt 2 125 Knoten enthielten. Keiner davon enthält „ConvTranspose“. Eine Änderung ausschließlich dieser Zählregel lässt daher deren Proxy-Gesamtwerte, Präfix-/Suffix-Anteile und Rangfolgen unverändert. Die neu berechneten Gesamtwerte stimmten für alle sieben Graphen mit den historischen Gesamtwerten überein. Im Rahmen der Prüfung wurden zudem 2 111 historische Kandidaten-Datensätze überprüft. Von den 450 späteren Konfigurationsdatensätzen verweisen 437 auf diese Hash-Werte der vollständigen Graphen. Den verbleibenden 13 Datensätzen fehlt ein Hash-Wert des vollständigen Modells, und einzelne Teilgraphen wurden nicht auf Operatoren überprüft. Abschnitt B.2.1 dokumentiert die Identitäten und Nachweise [95].

Die aktuelle gewichtete Bewertung nutzt die Erweiterung zur Zählung von Operationen in Abschnitt 6.2.2. Sie fügt explizite Regeln für die fünfzehn Knoten „Softmax“, „ReduceMax“, „Mod“ und „TopK“ hinzu, die im früheren Export nicht berücksichtigt wurden. Tabelle 6.1 enthält diese Regeln. Diese hinzugefügten Zählungen sind Teil der aktuellen Bewertung und haben keinen Einfluss auf die oben berichteten historischen Prüfungsergebnisse.

Tabelle C.4: In den Entwicklungsstudien verwendete historische arithmetische Ersatzgrößen. Bei Zählwerten kommen MAC-äquivalente und skalare Ersatzgrößen zum Einsatz. Tabelle 6.1 enthält die zusätzlichen Regeln, die bei der aktuellen Bewertung angewendet werden.

Operatorfamilie	Zählweise und Konvention
Conv, ConvInteger, QLinearConv	$NH_{out}W_{out}C_{out}(K_hK_wC_{in}/G)$. Bei explizitem Bias wird N_{out} addiert. Eine MAC-äquivalente Einheit pro Kernel-Produkt pro Ausgangskanal.
ConvTranspose	Gleiche Ausdrucks- und Bias-Konvention wie bei Conv. Historisches, auf dichten Ausgabewerten basierendes Surrogat, keine operatorgenaue MAC-Zählung.
MatMul, MatMulInteger, QLinearMatMul	$BMNK$. Formen werden durch Inferenz aus Werten oder Initialisierern abgeleitet. Pro Produkt eine MAC-äquivalente Einheit.
Gemm	$BMNK$. Bei explizitem Bias wird N_{out} addiert.
Add, Sub, Mul, Div	N_{out}. Eine skalare Proxy-Einheit pro Ausgabekomponente.
Batch-Normalisierung	$4N_{out}$. Fester Standardwert pro Ausgabeelement.
ReLU, LeakyReLU, Sigmoid, tanh, Softsign, Softplus, GELU, Clip	N_{out}. Fester Standardwert von einer Proxy-Einheit pro Ausgabeelement.
Resize, Upsample, Interpolate	$c_{mode}N_{out}$ mit $c_{mode} = 1, 8, 16$ für den Nächste-Nachbar-, linearen und kubischen Modus. Unbekannte Modi werden standardmäßig auf „eins“ gesetzt.
Sonstige Operatoren	Null, sofern nicht in aufgeführte Primitive zerlegt. Dazu gehören „Fused Attention“, „Pooling“, „Softmax“, „Layer Normalisation“, „Transpose“ und „Reshape“. Ihre Auswirkungen auf Laufzeit und Speicherbedarf bleiben beobachtbar.

C.5 Einfluss der Compiler-Optimierung auf die Ergebnisqualität

In einem früheren YOLOv7-Experiment wurde geprüft, ob eine zusätzliche Hailo-Compiler-Optimierungseinstellung die Ergebnisqualität wiederherstellen konnte. Dabei kam der interne B500-Evaluator anstelle der COCO-Bewertung der Hauptkampagne zum Einsatz. Die erzielten Ergebnisse beziehen sich daher ausschließlich auf diesen kontrollierten Vergleich.

Der begrenzte Hailo-Full-Test ändert die Optimierungsstufe von eins auf zwei. Die ausgewogene Voreinstellung, 500 Kalibrierungsbilder und eine Batchgröße von acht bleiben unverändert. Ein zusätzliches Modellskript wird nicht verwendet. Auf Hailo-8 sinkt der interne B500-Wert von 0,414 8 auf Stufe eins auf 0,409 8 auf Stufe zwei. Beide Konfigurationen erfüllen das Qualitätskriterium dieses Experiments nicht. Diese Werte

unterscheiden sich von den COCO-AP-Werten der Hauptstudie, und dieses Experiment testet keine Optimierung des MobileNet-Compilers. Für Hailo-10H liegt kein auswertbares Qualitätsergebnis vor, da in der Anfrage `hailo10` anstelle des registrierten `hailo10h` verwendet wurde. Das fehlende Ergebnis lässt keinen Vergleich der beiden Hailo-10H-Einstellungen zu.

Tabelle C.5: YOLOv7-Full-Qualität unter zwei Hailo-Optimierungsstufen, bewertet anhand der internen B500-Metrik. Diese Werte sind unabhängig vom COCO-AP der Hauptkampagne.

Backend	Stufe	Q	Q^{50}	Q^{75}	Entscheidung
Hailo-8	1	0,415	0,598	0,467	nicht bestanden
Hailo-8	2	0,410	0,596	0,463	nicht bestanden
Hailo-10H	1	0,420	0,610	0,472	nicht bestanden
Hailo-10H	2	–	–	–	nicht ausgewertet

D Durchsatz, Energie und Qualität der gemessenen Konfigurationen

Die folgenden Abbildungen erweitern die ausgewählten Vergleiche aus Kapitel 8 auf den gesamten Messraum für jedes Modell. Sie zeigen die 450 Konfigurationen mit Durchsatz- und Energiebeobachtungen über die drei Aufbauten hinweg. Darunter befinden sich 43 Konfigurationen, die außerhalb der primären 5%-Grenze für Qualitätsverlust liegen. Die Konfiguration Generic YOLOv7/H8 b009 weist keinen Energiewert auf und wird daher in diesen Diagrammen nicht berücksichtigt. Durchsatz, Energieverbrauch und numerische Qualität können somit vor der Filterung überprüft werden [96].

Jeder Punkt steht für eine Ausführungskonfiguration mit dem aufgezeichneten prozessbezogenen Median-Durchsatz und der mittleren kalibrierten Energie (einschließlich Host) pro fertiggestelltem Bild. Die Form der Markierung unterscheidet die beiden geteilten Implementierungen und die beiden Full-Alternativen. Die Farbe zeigt die numerische Top-1-Genauigkeit oder den aufgezeichneten $AP_{50:95}$ an. Die Detektormetrik ist COCO $AP_{50:95}$. Die drei vertikal angeordneten Felder für jedes Modell verwenden eine gemeinsame Farbskala, ihre Achsen sind jedoch separat skaliert. Die Farben lassen sich nicht über verschiedene Modelle oder Aufgaben hinweg vergleichen.

Schwarze Konturen markieren die Durchsatz-Energie-Grenze für jedes Modell und jeden Beschleuniger. Eine Konfiguration liegt auf dieser Grenze, wenn keine andere gemessene Alternative eine Metrik verbessert, ohne die andere zu verschlechtern. Bei Verwendung ungerundeter Werte und unter Berücksichtigung von Gleichständen ergeben sich 34 Konfigurationen in 21 Kombinationen. Die Bestimmung dieser Grenze erfolgt ohne Qualitätsfilterung. Die Farbe zeigt die Qualität separat an, sodass bei einer Einsatzentscheidung auch das erforderliche Qualitätsniveau überprüft werden muss. Die Abbildungen beschreiben gemessene Alternativen unter Berücksichtigung ihrer tatsächlichen Laufzeitumgebungen und Ablaufsteuerungen. Sie legen keine Dominanz bei gleicher Qualität oder erreichbaren Zwischenkonfigurationen fest.

Das Auswertungswerkzeug generiert diese Ansichten aus derselben numerischen Tabelle wie der Einsatzvergleich. Dazu gehört YOLO11l/DeepX b511 mit seiner gemessenen Generic-Energie. Die Bezeichnungen F und E kennzeichnen die schnellste bzw. die energieeffizienteste Ausführungskonfiguration für ein Ausführungsmodul. N steht für Native und G für Generic. Geringe Abweichungen sollten im Zusammenhang mit den beobachteten Wiederholungen und den in den Hauptkapiteln erörterten Messgrenzen betrachtet werden.

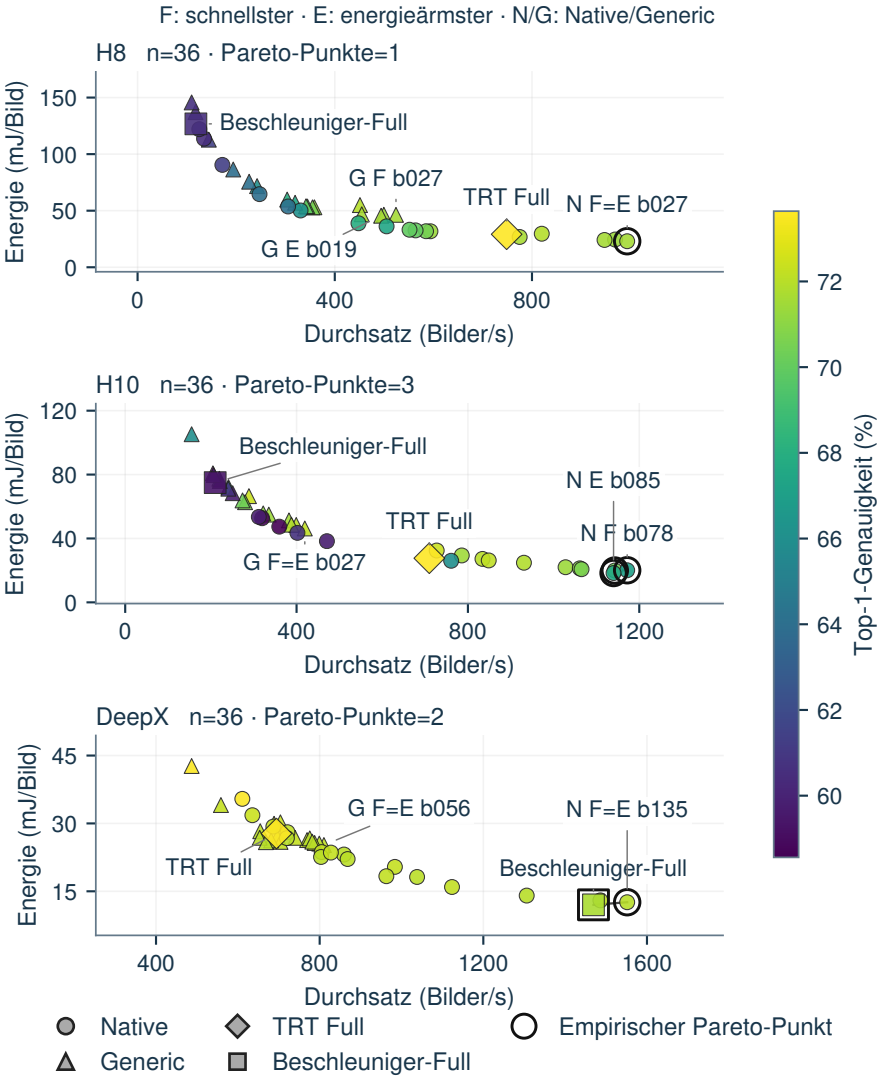


Abbildung D.1: MobileNetV3 Large: 108 gemessene Ausführungskonfigurationen. Die drei lokalen Zwei-Ziel-Grenzen enthalten einen, drei bzw. zwei Punkte. Die schnellste Split-Variante läuft auf DeepX. Ihr bescheidener Durchsatzvorteil gegenüber der schnellsten Full-Konfiguration über alle untersuchten Systeme bringt keine Energieeinsparung mit sich. Schwarze Umrisse markieren die ungefilterte Grenze.

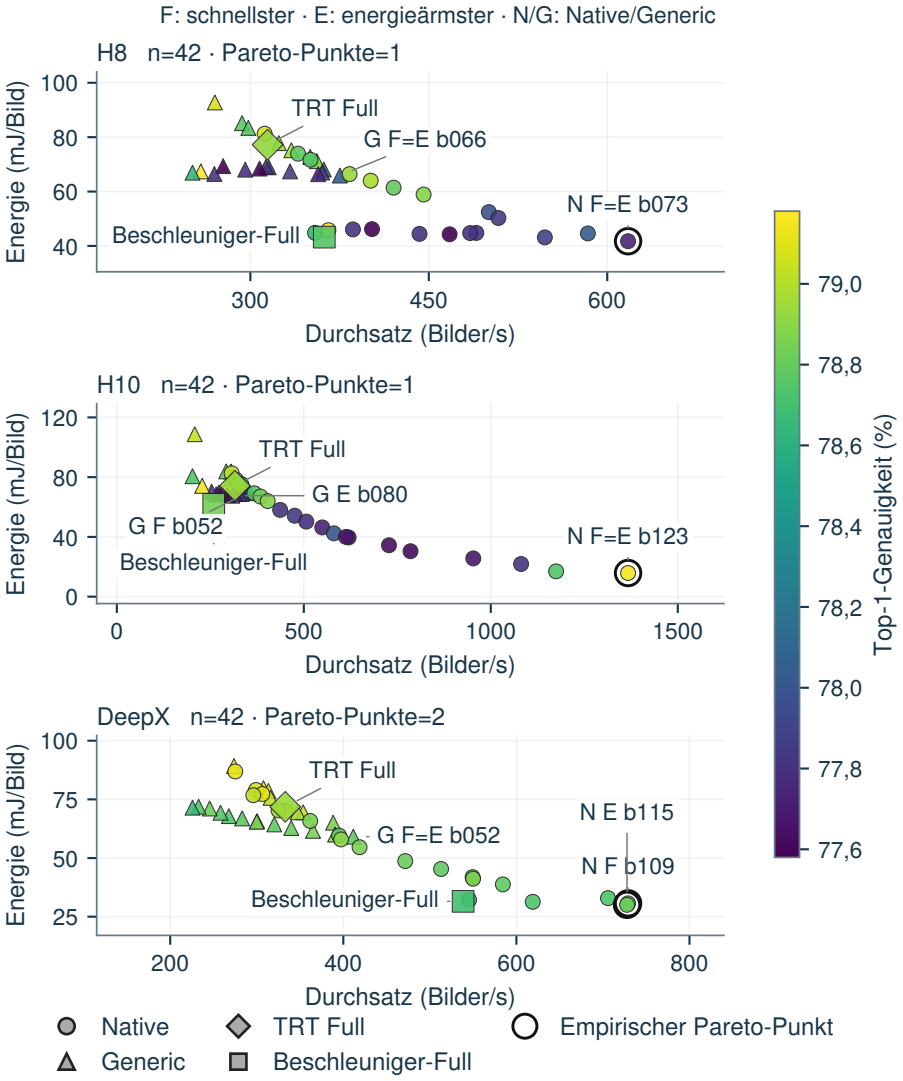


Abbildung D.2: RegNet-X 1.6GF: 126 gemessene Ausführungskonfigurationen. H8 und H10 weisen jeweils einen Grenzpunkt mit zwei Zielgrößen auf, DeepX weist zwei solche Punkte auf. Die H10-Split-Konfiguration liefert unter den Hauptoptionen die stärkste kombinierte Verbesserung bei Durchsatz und Energieverbrauch. Die Diagramme enthalten alle erfassten numerischen Qualitätsstufen.

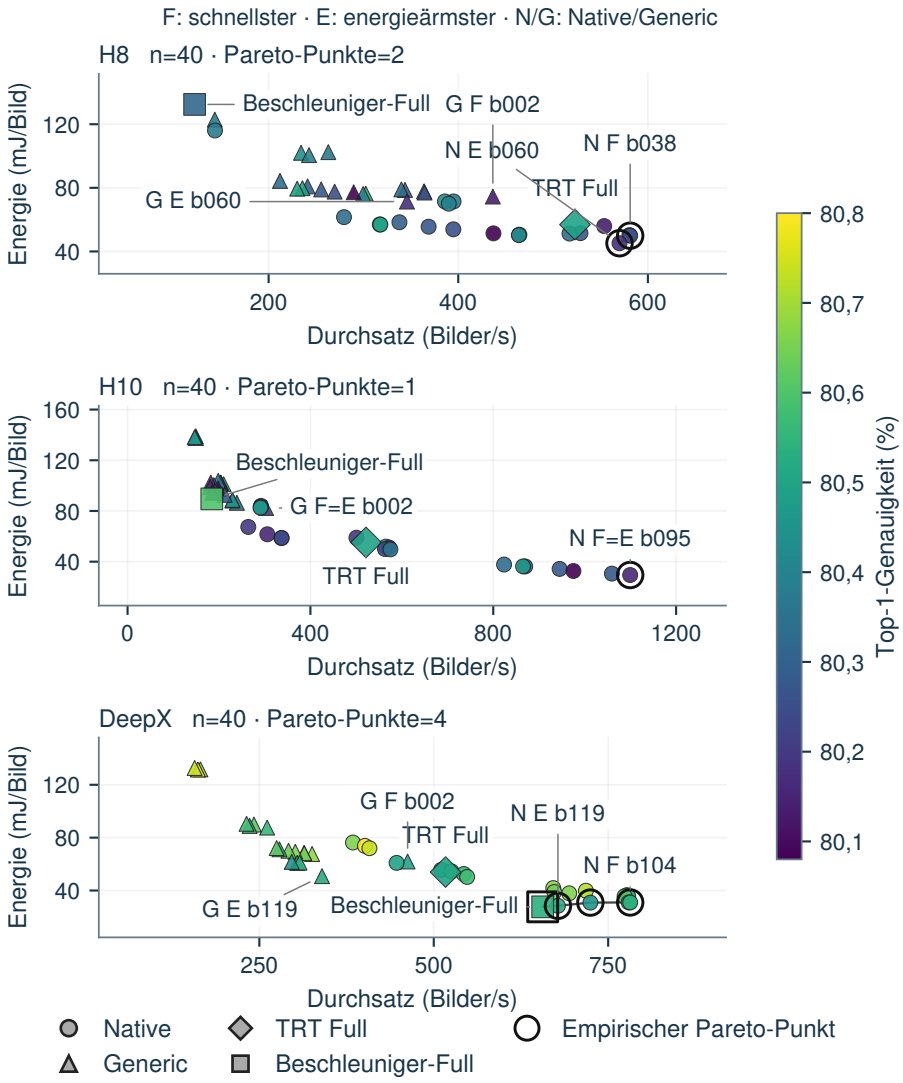


Abbildung D.3: ResNet-50: 120 gemessene Ausführungskonfigurationen. H8 und DeepX bieten mehrere lokale Auswahlmöglichkeiten zwischen Durchsatz und Energieverbrauch. Die über alle untersuchten Systeme schnellste Split-Variante auf H10 übertrifft die schnellste Full-Konfiguration über alle untersuchten Systeme beim Durchsatz, verbraucht jedoch mehr Energie.

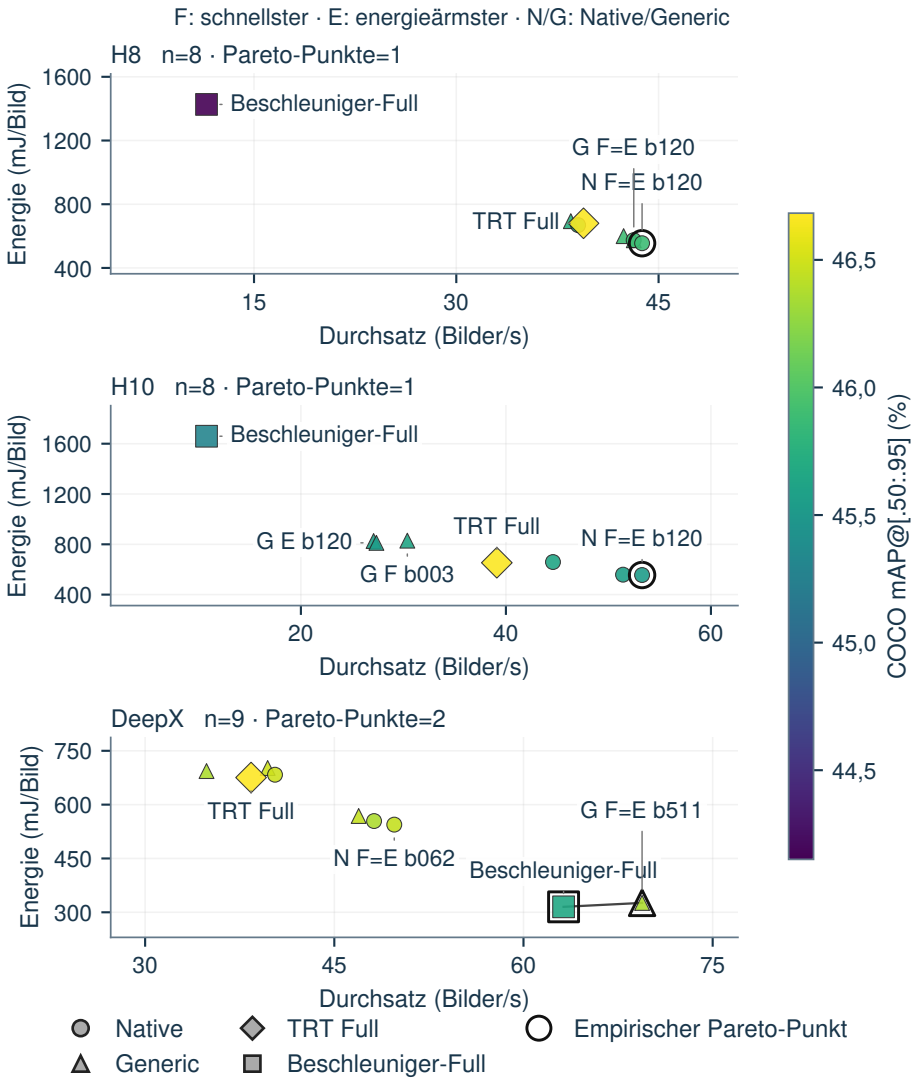


Abbildung D.4: YOLO11l: 25 gemessene Ausführungskonfigurationen, einschließlich Generic DeepX b511. H8 und H10 weisen jeweils einen ungefilterten Grenzpunkt auf, DeepX hingegen zwei. Die zusätzliche Split-Konfiguration übertrifft den schnellsten Full-Durchsatz um 9,9%, verbraucht dabei jedoch 3,5% mehr Energie pro Bild. DeepX Full bleibt die energieeffizientere Alternative.

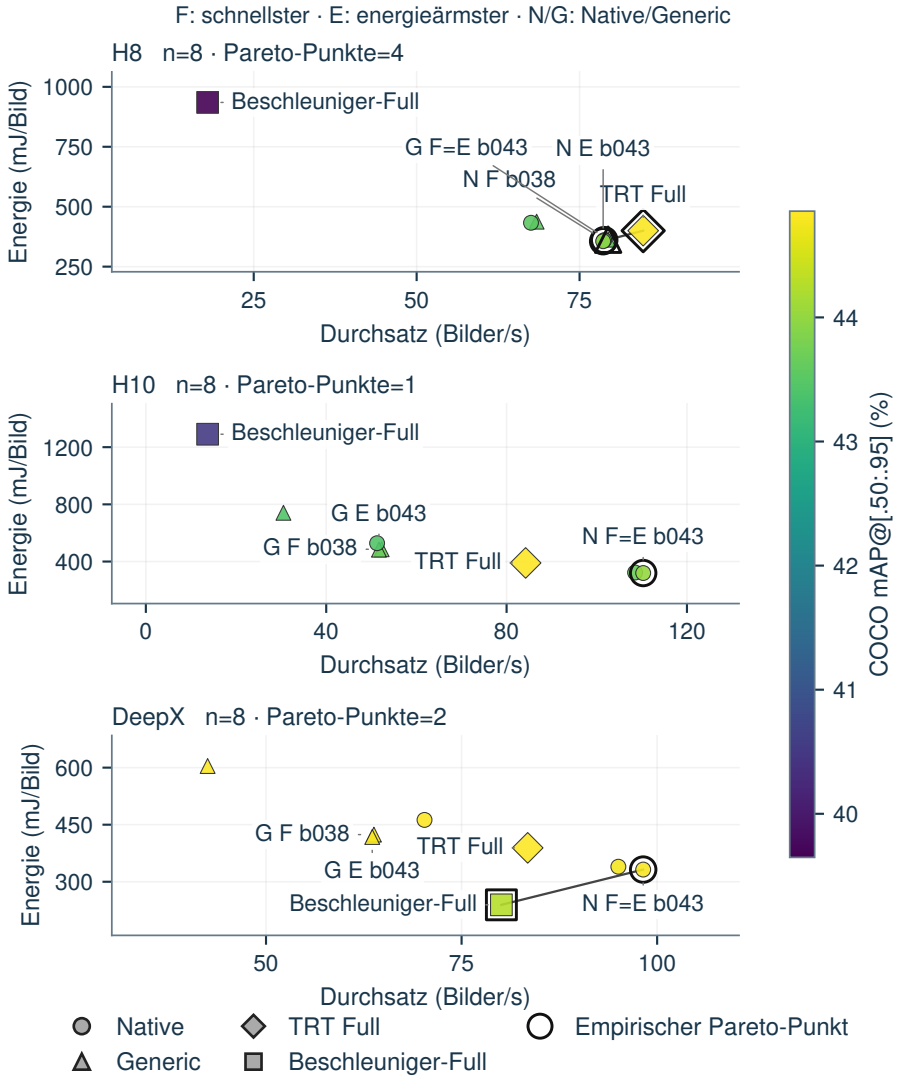


Abbildung D.5: YOLO26m: 24 gemessene Ausführungskonfigurationen. Auf H8 sind vier Konfigurationen nichtdominiert, auf DeepX zwei. Die über alle untersuchten Systeme schnellste Split-Variante auf H10 verbraucht weniger Energie als die schnellste Full-Konfiguration über alle untersuchten Systeme. DeepX Full verbraucht noch weniger Energie. Die Auswahl einer Full-Referenz nach Durchsatz minimiert deren Energieverbrauch nicht.

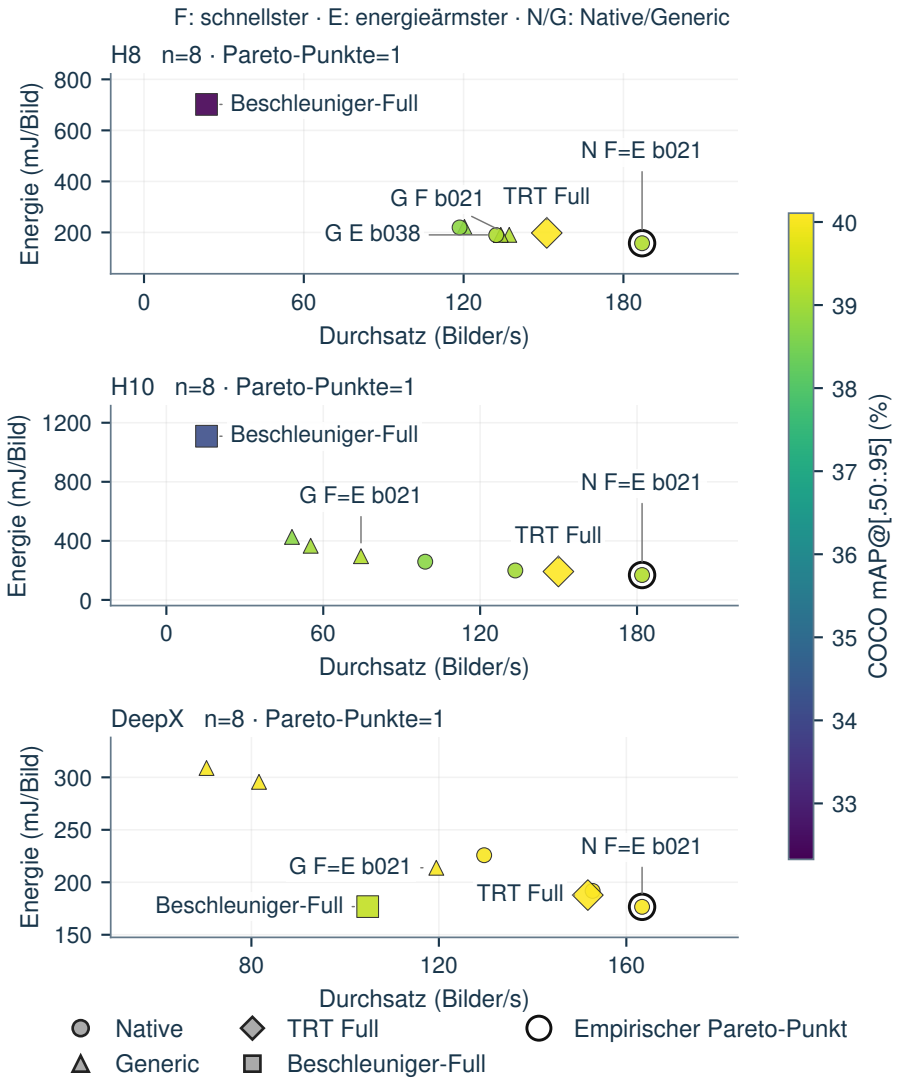


Abbildung D.6: YOLO26s: 24 gemessene Ausführungskonfigurationen. Jeder Aufbau verfügt über genau eine Konfiguration auf der lokalen Zwei-Ziel-Grenze. Die schnellste Split-Konfiguration auf H8 verbessert sowohl den Durchsatz als auch den Energieverbrauch im Vergleich zur schnellsten Full-Konfiguration über alle untersuchten Systeme. Das Ergebnis ist auf die drei getesteten Schnitte pro Aufbau beschränkt und kann nicht jede gültige Graphgrenze charakterisieren.

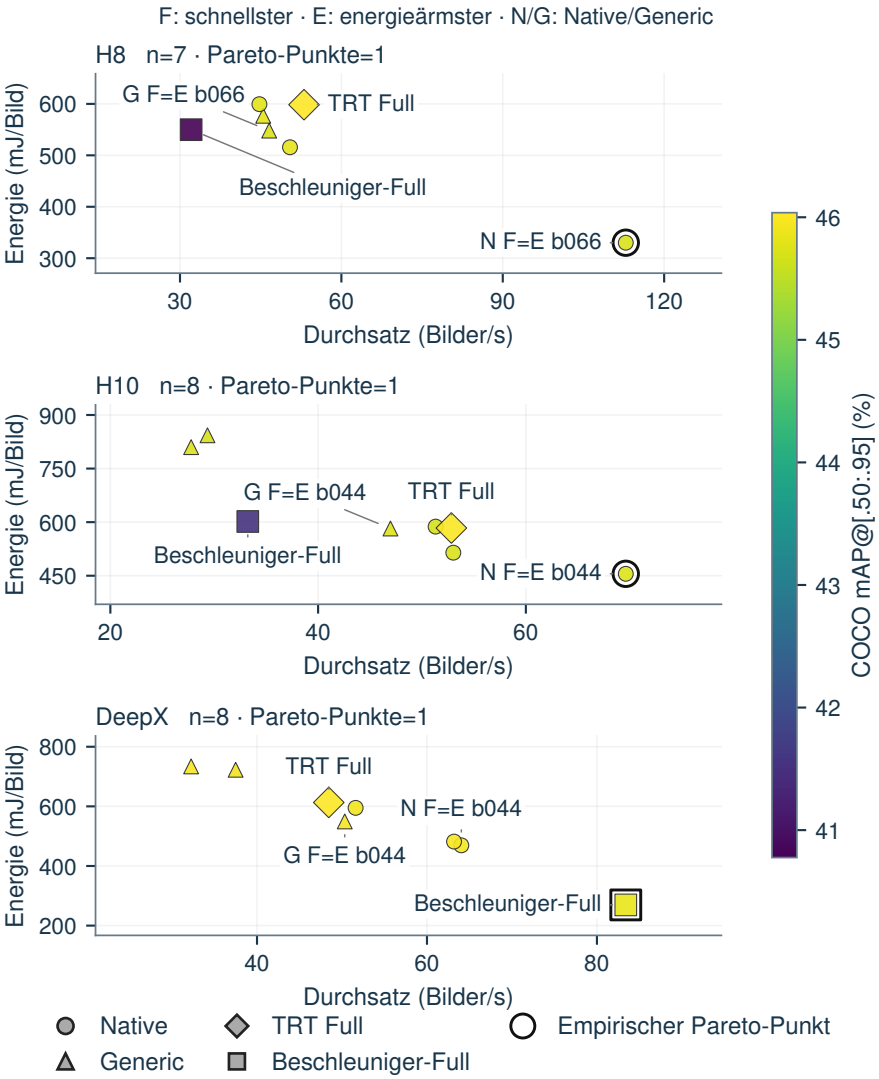


Abbildung D.7: YOLOv7: 23 grafisch dargestellte Ausführungskonfigurationen. Der Punkt Generic H8 b009 wurde weggelassen, da für ihn keine Energiebeobachtung vorliegt. Die schnellste Split-Konfiguration, H8 b066, übertrifft den Durchsatz der globalen DeepX Full-Konfiguration, verbraucht jedoch mehr Energie pro Bild. Die Grafik zeigt zudem die erheblichen Qualitätsunterschiede zwischen den Full-Pfaden des Beschleunigers. Frühere Studien zu Decodern und Vervollständigung tragen zur Erklärung verschiedener Aspekte des Ergebnisses bei und sind von diesen Beobachtungen getrennt zu betrachten.

Literaturverzeichnis

Literatur

[1] M. Abadi, P. Barham, J. Chen, Z. Chen, A. Davis, J. Dean, M. Devin, S. Ghemawat, G. Irving, M. Isard u. a. „TensorFlow: A System for Large-Scale Machine Learning“. In: *12th USENIX Symposium on Operating Systems Design and Implementation (OSDI 16)*. 2016, S. 265–283. URL: https://www.usenix.org/conference/osdi16/technical-sessions/presentation/abadi.

[2] Advanced Micro Devices. *AMD Kria System-on-Modules*. URL: https://www.amd.com/en/products/system-on-modules/kria.html (besucht am 04. 11. 2026).

[3] E. Aghapour, D. Sapra, A. D. Pimentel und A. Pathania. „ARM-CO-UP: ARM Cooperative Utilization of Processors“. In: *ACM Transactions on Design Automation of Electronic Systems* 29.5 (2024), 86:1–86:30. DOI: 10.1145/3656472.

[4] G. Agosta, A. Barenghi, T. Ciesielczyk, R. Dutta, W. Fornaciari, T. Goubier, J. Hagemeyer, L. Kosmann, N. Mainardi, A. Oleksiak, G. Pelosi, W. Piatek, C. Pieper, M. Porrmann, D. Schlitt und M. Zanella. „The M2DC Approach towards Resource-efficient Computing“. In: *Opportunities and Challenges for European Projects (EPS Portugal 2017/2018)*. Beschreibt das RECS-Konzept mit drei Säulen (flexibles RECS|Box-Gehäuse, Verbesserungen der Systemeffizienz, Softwareschnittstellen) und hebt heterogene Mikroserverkonfigurationen mit ARM-, x86-, FPGA- und GPU-Knoten sowie proaktives Leistungs- und Wärmemanagement hervor. SCITEPRESS, 2019, S. 150–176. DOI: 10.5220/0008862601500176.

[5] Aim-TTi. *CPX200D and CPX200DP DC Power Supplies*. 2026. URL: https://www.aimtti.com/go/cpx/index.php?p=index-cpx200d (besucht am 28. 08. 2026).

[6] L. Alt, A. Kozhokanova, T. Ilsche, C. Terboven und M. S. Mueller. „An Experimental Setup to Evaluate RAPL Energy Counters for Heterogeneous Memory“. In: *Proceedings of the 15th ACM/SPEC International Conference on Performance Engineering (ICPE)*. 2024, S. 71–82. DOI: 10.1145/3629526.3645052.

[7] Analog Devices. *LT8609S: 42V, 2A/3A Peak Synchronous Step-Down Regulator with 2.5 microampere Quiescent Current*. Version D. Okt. 2020. URL: https://www.analog.com/media/en/technical-documentation/data-sheets/lt8609s.pdf (besucht am 04. 11. 2026).

[8] Analog Devices. *LT8648S/LT8648SP: 42V, 15A Synchronous Step-Down Silent Switcher 2*. Version E. Feb. 2025. URL: https://www.analog.com/media/en/technical-documentation/data-sheets/lt8648s.pdf (besucht am 04. 11. 2026).

[9] Apache Software Foundation. *Apache Parquet: Overview and File Format*. URL: https://parquet.apache.org/docs/overview/ (besucht am 04. 11. 2026).

[10] B. Aslan und A. Yilmazer-Metin. „A Study on Power and Energy Measurement of NVIDIA Jetson Embedded GPUs Using Built-in Sensor“. In: *2022 7th International Conference on Computer Science and Engineering (UBMK)*. 2022, S. 479–484. DOI: 10.1109/UBMK55850.2022.9919522.

[11] A. Bakhtiarnia, N. Milošević, Q. Zhang, D. Bajović und A. Iosifidis. „Dynamic Split Computing for Efficient Deep Edge Intelligence“. In: *2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2023. DOI: 10.1109/ICASSP49357.2023.10096914.

[12] S. P. Baller, A. Jindal, M. Chadha und M. Gerndt. „DeepEdgeBench: Benchmarking Deep Neural Networks on Edge Devices“. In: *2021 IEEE International Conference on Cloud Engineering (IC2E)*. Zugriff am 2026-02-17. 2021, S. 20–30. DOI: 10.1109/IC2E52221.2021.00016.

[13] A. Bochkovskiy, C.-Y. Wang und H.-Y. M. Liao. *YOLOv4: Optimal Speed and Accuracy of Object Detection*. 2020. DOI: 10.48550/arXiv.2004.10934. arXiv: 2004.10934 [cs.CV].

[14] Bureau International des Poids et Mesures (BIPM). *Resolution 10 of the 22nd CGPM: Symbol for the Decimal Marker*. 2003. DOI: 10.59161/CGPM2003RES10E.

[15] T. Chen, T. Moreau, Z. Jiang, L. Zheng, E. Q. Yan, H. Shen, M. Cowan, L. Wang, Y. Hu, L. Ceze, C. Guestrin und A. Krishnamurthy. „TVM: An Automated End-to-End Optimizing Compiler for Deep Learning“. In: *13th USENIX Symposium on Operating Systems Design and Implementation (OSDI)*. 2018, S. 578–594. URL: https://www.usenix.org/conference/osdi18/presentation/chen.

[16] COCO Consortium. *COCO API: Official `pycocotools` Detection Evaluator*. Offizielle Implementierung der COCO-Auswertungsparameter, einschließlich IoU-Schwellenwerten von 0.50 bis 0.95 und 101 Recall-Positionen. 2015. URL: https://github.com/cocodataset/cocoapi/blob/master/PythonAPI/pycocotools/cocoeval.py (besucht am 10. 08. 2026).

[17] congatec. *conga-SA8: SMARC Module Based on Intel Processors*. URL: https://www.congatec.com/de/produkte/smarc/conga-sa8/ (besucht am 05. 11. 2026).

[18] congatec. *conga-SMX8-Plus: SMARC Module Based on NXP i.MX 8M Plus*. URL: https://www.congatec.com/en/products/smarc/conga-smx8-plus/ (besucht am 05. 11. 2026).

[19] I. Dagli, A. Cieslewicz, J. McClurg und M. E. Belviranli. „AxoNN: Energy-Aware Execution of Neural Network Inference on Multi-Accelerator Heterogeneous SoCs“. In: *Proceedings of the 59th ACM/IEEE Design Automation Conference*. 2022, S. 1069–1074. DOI: 10.1145/3489517.3530572.

[20] P. Dai, B. Han, K. Li, X. Xu, H. Xing und K. Liu. „Joint Optimization of Device Placement and Model Partitioning for Cooperative DNN Inference in Heterogeneous Edge Computing“. In: *IEEE Transactions on Mobile Computing* 24.1 (2025), S. 210–226. DOI: 10.1109/TMC.2024.3457793.

[21] M. Dauner, M. Steinberg, A. Brunnert, B. Schicker und B. Zönnchen. „Evaluating the Influence of Measurement Frequency on Energy Readings Using Intel RAPL and NVIDIA NVML“. In: *ACM SIGENERGY Energy Informatics Review* 6.2 (Juli 2026). URL: https://hotcarbon.org/assets/2026/paper-46.pdf.

[22] K. Deb, A. Pratap, S. Agarwal und T. Meyarivan. „A fast and elitist multiobjective genetic algorithm: NSGA-II“. In: *IEEE Transactions on Evolutionary Computation* 6.2 (2002), S. 182–197. DOI: 10.1109/4235.996017.

[23] DeepL. *About DeepL Translator*. URL: https://support.deepl.com/hc/en-us/articles/360019924399-About-DeepL-Translator (besucht am 04. 11. 2026).

[24] DEEPX Co., Ltd. *DEEPX DX-M1 Chip AI Accelerator Brief-D26-V1, 2026, p. 1*. 2026. URL: https://cdn.deepx.ai/wp-content/uploads/2026/09/04114116/DEEPX-DX-M1-Chip-AI-Accelerator-E-Brochure.pdf (besucht am 28. 10. 2026).

[25] DEEPX Co., Ltd. *DEEPX DX-M1 M.2 Module AI Accelerator Brief-D26-V1, 2026, p. 1*. 2026. URL: https://cdn.deepx.ai/wp-content/uploads/2026/09/04110622/DEEPX-DX-M1-M.2-Module-AI-Accelerator-E-Brochure.pdf (besucht am 28. 10. 2026).

[26] DEEPX Co., Ltd. *DEEPX DX-RT: Model Inference, SDK 2.3.3, Configure Inference Options*. URL: https://developer.deepx.ai/tech-docs/2.3.3/DXNN-SDK/DX-RT/Model_Inference/ (besucht am 28. 10. 2026).

[27] DEEPX Co., Ltd. *DX-COM: Execution of the Compiler. DXNN SDK 2.3.3 Documentation*. URL: https://developer.deepx.ai/tech-docs/2.3.3/DXNN-SDK/DX-COM/02_06_Execution_of_DX-COM/ (besucht am 04. 11. 2026).

[28] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li und L. Fei-Fei. „ImageNet: A Large-Scale Hierarchical Image Database“. In: *2009 IEEE Conference on Computer Vision and Pattern Recognition*. 2009, S. 248–255. DOI: 10.1109/CVPR.2009.5206848.

[29] X. Dong, B. De Salvo, M. Li, C. Liu, Z. Qu, H. T. Kung und Z. Li. „SplitNets: Designing Neural Architectures for Efficient Distributed Computing on Head-Mounted Systems“. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2022. URL: https://arxiv.org/abs/2204.04705.

[30] draw.io Ltd und draw.io AG. *draw.io Documentation*. URL: https://www.drawio.com/docs/ (besucht am 04. 11. 2026).

[31] V. Dumoulin und F. Visin. „A guide to convolution arithmetic for deep learning“. In: *arXiv:1603.07285* (2016). Erläutert den Zusammenhang zwischen Faltung und transponierter Faltung sowie die Ausgabeformen. URL: https://arxiv.org/pdf/1603.07285.

[32] EA Elektro-Automatik. *EA-EL 9000 DT: Programmable Electronic DC Loads, 400 W–1200 W*. 2018. URL: https://elektroautomatik.com/shop/media/pdf/f7/49/e9/datasheet_el9000dt.pdf (besucht am 04. 11. 2026).

[33] B. Efron und R. J. Tibshirani. *An Introduction to the Bootstrap*. Bd. 57. Monographs on Statistics and Applied Probability. Chapman & Hall, 1993. DOI: 10.1201/9780429246593.

[34] A. E. Eshratifar, M. S. Abrishami und M. Pedram. „JointDNN: An Efficient Training and Inference Framework for Intelligent Mobile Cloud Computing“. In: *IEEE Transactions on Mobile Computing* 20.2 (2021). Auch als arXiv:1801.08618 verfügbar., S. 565–576. DOI: 10.1109/TMC.2019.2947893.

[35] Espressif Systems. *ESP32 Series Datasheet*. Version 5.3. Juli 2026. URL: https://www.espressif.com/sites/default/files/documentation/esp32_datasheet_en.pdf (besucht am 04. 11. 2026).

[36] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn und A. Zisserman. „The PASCAL Visual Object Classes (VOC) Challenge“. In: *International Journal of Computer Vision* 88.2 (2010), S. 303–338. DOI: 10.1007/s11263-009-0275-4.

[37] Fluke Corporation. *Fluke 179 True-RMS Digital Multimeter*. URL: https://www.fluke.com/en-us/product/electrical-testing/digital-multimeters/fluke-179 (besucht am 04. 11. 2026).

[38] Gemma Team. *Gemma 3 Technical Report*. 2025. arXiv: 2503.19786. URL: https://arxiv.org/abs/2503.19786.

[39] S. Grafenhorst, K. Förderer und V. Hagenmeyer. „Distribution grid monitoring based on feature propagation using smart plugs“. In: *Energy Informatics* 7, 116 (2024). DOI: 10.1186/s42162-024-00427-y. (Besucht am 27. 02. 2026).

[40] P. Gralka, C. Müller, M. Heinemann, G. Reina, D. Weiskopf und T. Ertl. „Power overwhelming: the one with the oscilloscopes“. In: *Journal of Visualization* 27.6 (2024), S. 1171–1193. DOI: 10.1007/s12650-024-01001-0.

[41] R. Griessl. *VEDLIoT Deliverable D3.3: Evaluation of the DL accelerator designs*. Techn. Ber. Version 1.1. VEDLIoT Project (H2020 Grant Agreement No. 957197), Okt. 2022.

[42] R. Griessl u. a. *VEDLIoT Deliverable D7.5: Pilot Use Case Demonstration*. Techn. Ber. Zugriff am 2026-02-17. VEDLIoT (H2020 Grant Agreement No. 957197), 2024. URL: https://vedliot.eu/vedliot-deliverables/D75-VEDLIoT---Pilot-Use-Case-Demonstration.pdf.

[43] R. Griessl, F. Porrmann, N. Kucza, K. Mika, J. Hagemeyer, M. Kaiser, M. Porrmann, M. Tassemeier, M. Flottmann, F. Qararyah, M. Waqar, P. Trancoso, D. Ödman, K. Gugala und G. Latosinski. „Evaluation of heterogeneous AIoT Accelerators within VEDLIoT“. In: *Design, Automation & Test in Europe Conference (DATE)*. 2023. URL: https://past.date-conference.com/proceedings-archive/2023/DATA/4017.pdf.

[44] X. Guo, A. D. Pimentel und T. Stefanov. „Automated Exploration and Implementation of Distributed CNN Inference at the Edge“. In: *IEEE Internet of Things Journal* 10.7 (2023), S. 5843–5858. DOI: 10.1109/JIOT.2023.3237572.

[45] Hailo. *Hailo-8 AI Accelerator*. Zugriff am 2026-02-17. 2026. URL: https://hailo.ai/products/ai-accelerators/hailo-8-ai-accelerator/.

[46] Hailo Technologies. *Model Optimization. Hailo Model Zoo Documentation*. URL: https://github.com/hailo-ai/hailo_model_zoo/blob/master/docs/OPTIMIZATION.rst (besucht am 20. 08. 2026).

[47] Hailo Technologies Ltd. *Hailo AI Software Suite: Dataflow Compiler*. URL: https://hailo.ai/products/hailo-software/hailo-ai-software-suite/ (besucht am 04. 11. 2026).

[48] Hailo Technologies Ltd. *Hailo-10H AI Accelerator Product Brief, 07/2025*. 2025. URL: https://hailo.ai/hailo-files/hailo-10h-product-brief-en/ (besucht am 28. 10. 2026).

[49] Hailo Technologies Ltd. *Hailo-10H M.2 Key M ET Product Brief*. URL: https://hailo.ai/files/hailo-10h-m-2-et-product-brief-en/ (besucht am 28. 10. 2026).

[50] Hailo Technologies Ltd. *Hailo-8 Hardware Architecture: Device Control and Host Interface*. Herstellerantwort von Omri, 12. Juni 2025. 2025. URL: https://community.hailo.ai/t/hailo8-hardware-architecture/15454 (besucht am 28. 10. 2026).

[51] Hailo Technologies Ltd. *Hailo: The Hailo Architecture*. URL: https://hailo.ai/products/technology/ (besucht am 28. 10. 2026).

[52] Hailo Technologies Ltd. *HailoRT: Inference Runtime for Hailo Devices*. URL: https://github.com/hailo-ai/hailort (besucht am 04. 11. 2026).

[53] M. A. Hamdi, F. Daghero, G. M. Sarda, J. Van Delm, A. Symons, L. Benini, M. Verhelst, D. Jahier Pagliari und A. Burrello. *MATCH: Model-Aware TVM-based Compilation for Heterogeneous Edge Devices*. 2024. DOI: 10.48550/arXiv.2410.08855. arXiv: 2410.08855 [cs.DC].

[54] Y. Hao, N. Ding, W. Xia, H. Ge und L. Xu. „DNN Partitioning for Cooperative Inference in Edge Intelligence: Modeling, Solutions, Toolchains“. In: *ACM Computing Surveys* 58.8 (2026). DOI: 10.1145/3786145.

[55] C. R. Harris, K. J. Millman, S. J. van der Walt, R. Gommers, P. Virtanen, D. Cournapeau, E. Wieser, J. Taylor, S. Berg, N. J. Smith, R. Kern, M. Picus, S. Hoyer, M. H. van Kerkwijk, M. Brett, A. Haldane, J. Fernández del Río, M. Wiebe, P. Peterson, P. Gérard-Marchant, K. Sheppard, T. Reddy, W. Weckesser, H. Abbasi, C. Gohlke und T. E. Oliphant. „Array Programming with NumPy“. In: *Nature* 585.7825 (2020), S. 357–362. DOI: 10.1038/s41586-020-2649-2.

[56] K. He, X. Zhang, S. Ren und J. Sun. „Deep Residual Learning for Image Recognition“. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, S. 770–778. DOI: 10.1109/CVPR.2016.90.

[57] M. Horowitz. „1.1 Computing's Energy Problem (and What We Can Do About It)“. In: *2014 IEEE International Solid-State Circuits Conference Digest of Technical Papers (ISSCC)*. 2014, S. 10–14. DOI: 10.1109/ISSCC.2014.6757323.

[58] A. Howard, M. Sandler, G. Chu, L.-C. Chen, B. Chen, M. Tan, W. Wang, Y. Zhu, R. Pang, V. Vasudevan, Q. V. Le und H. Adam. „Searching for MobileNetV3“. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. 2019, S. 1314–1324. URL: https://openaccess.thecvf.com/content_ICCV_2019/html/Howard_Searching_for_MobileNetV3_ICCV_2019_paper.html.

[59] C. Hu und B. Li. „Distributed Inference with Deep Learning Models across Heterogeneous Edge Devices“. In: *IEEE Conference on Computer Communications (INFOCOM)*. 2022, S. 330–339. DOI: 10.1109/INFOCOM48880.2022.9796896.

[60] C. Hu, W. Bao, D. Wang und F. Liu. „Dynamic Adaptive DNN Surgery for Inference Acceleration on the Edge“. In: *IEEE Conference on Computer Communications (INFOCOM)*. 2019, S. 1423–1431. DOI: 10.1109/INFOCOM.2019.8737614.

[61] D. Hu und B. Krishnamachari. „Fast and Accurate Streaming CNN Inference via Communication Compression on the Edge“. In: *Proceedings of the 5th IEEE/ACM Symposium on Internet of Things Design and Implementation (IoTDI)*. 2020, S. 157–163. DOI: 10.1109/IOTDI49375.2020.00023.

[62] Y. Hu, C. Imes, X. Zhao, S. Kundu, P. A. Beerel, S. P. Crago und J. P. Walters. „PipeEdge: Pipeline Parallelism for Large-Scale Model Inference on Heterogeneous Edge Devices“. In: *25th Euromicro Conference on Digital System Design (DSD)*. 2022, S. 298–307. DOI: 10.1109/DSD57027.2022.00048.

[63] I. Hubara, Y. Nahshan, Y. Hanani, R. Banner und D. Soudry. „Accurate Post Training Quantization With Small Calibration Sets“. In: *Proceedings of the 38th International Conference on Machine Learning*. Bd. 139. Proceedings of Machine Learning Research. 2021, S. 4466–4475. URL: https://proceedings.mlr.press/v139/hubara21a.html.

[64] J. D. Hunter. „Matplotlib: A 2D Graphics Environment“. In: *Computing in Science & Engineering* 9.3 (2007), S. 90–95. DOI: 10.1109/MCSE.2007.55.

[65] B. Jacob, S. Kligys, B. Chen, M. Zhu, M. Tang, A. Howard, H. Adam und D. Kalenichenko. „Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference“. In: *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2018, S. 2704–2713. DOI: 10.1109/CVPR.2018.00286.

[66] B. Jeon, S. Park, P. Liao, S. Xu, T. Chen und Z. Jia. „Collage: Seamless Integration of Deep Learning Backends with Automatic Placement“. In: *International Conference on Parallel Architectures and Compilation Techniques (PACT)*. ACM, 2022, S. 517–529. DOI: 10.1145/3559009.3569651.

[67] J. S. Jeong, J. Lee, D. Kim, C. Jeon, C. Jeong, Y. Lee und B.-G. Chun. „Band: Coordinated Multi-DNN Inference on Heterogeneous Mobile Processors“. In: *Proceedings of the 20th Annual International Conference on Mobile Systems, Applications and Services*. ACM, 2022, S. 235–247. DOI: 10.1145/3498361.3538948.

[68] jetson-stats. *jtop API Reference: Power*. URL: https://rnext.it/jetson_stats/reference/jtop.html (besucht am 10. 11. 2026).

[69] F. Jia, D. Zhang, T. Cao, S. Jiang, Y. Liu, J. Ren und Y. Zhang. „CoDL: Efficient CPU–GPU Co-execution for Deep Learning Inference on Mobile Devices“. In: *Proceedings of the 20th Annual International Conference on Mobile Systems, Applications and Services*. ACM, 2022, S. 209–221. DOI: 10.1145/3498361.3538932.

[70] G. Jocher und J. Qiu. *Ultralytics YOLO11*. Version 11.0.0. Dokumentation: https://docs.ultralytics.com/models/yolo11/. 2024. URL: https://github.com/ultralytics/ultralytics.

[71] G. Jocher, J. Qiu, M. Liu, S. Lyu, F. C. Akyon und M. E. Kalfaoglu. *Ultralytics YOLO26: Unified Real-Time End-to-End Vision Models*. 2026. DOI: 10.48550/arXiv.2606.03748. arXiv: 2606.03748 [cs.CV].

[72] M. Kaiser, R. Griessl, N. Kucza, C. Haumann, L. Tigges, K. Mika, J. Hagemeyer, F. Porrmann, U. Rückert u. a. „VEDLIoT: Very Efficient Deep Learning in IoT“. In: *2022 Design, Automation & Test in Europe Conference & Exhibition (DATE)*. 2022, S. 963–968.

[73] Y. Kang, J. Hauswald, C. Gao, A. Rovinski, T. Mudge, J. Mars und L. Tang. „Neurosurgeon: Collaborative Intelligence Between the Cloud and Mobile Edge“. In: *Proceedings of the Twenty-Second International Conference on Architectural Support for Programming Languages and Operating Systems (ASPLOS '17)*. ACM, 2017, S. 615–629. DOI: 10.1145/3037697.3037698.

[74] G. Karypis und V. Kumar. „A Fast and High Quality Multilevel Scheme for Partitioning Irregular Graphs“. In: *SIAM Journal on Scientific Computing* 20.1 (1998), S. 359–392.

[75] D. Katare, M. Zhou, Y. Chen, M. Janssen und A. Y. Ding. „Energy-Aware Vision Model Partitioning for Edge AI“. In: *Proceedings of the 40th ACM/SIGAPP Symposium on Applied Computing (SAC '25)*. 2025. DOI: 10.1145/3672608.3707792.

[76] W. Kester. *Understand SINAD, ENOB, SNR, THD, THD + N, and SFDR so You Don't Get Lost in the Noise Floor*. 2009. URL: https://www.analog.com/media/en/training-seminars/tutorials/MT-003.pdf (besucht am 06. 06. 2026).

[77] K. Koschinsky. *Hailo 10H: Measure Power Draw*. Angaben zur Bestückung des Starter-Kit-Moduls mit einem INA-Messbaustein. 29. Jan. 2026. URL: https://community.hailo.ai/t/hailo-10h-measure-power-draw/18619 (besucht am 10. 11. 2026).

[78] F. Kreß, E. M. El Annabi, T. Hotfilter, J. Hoefer, T. Harbaum und J. Becker. „Automated Deep Neural Network Inference Partitioning for Distributed Embedded Systems“. In: *IEEE Computer Society Annual Symposium on VLSI (ISVLSI)*. 2024. DOI: 10.1109/ISVLSI61997.2024.00019.

[79] F. Kreß, J. Hoefer, T. Hotfilter, I. Walter, V. Sidorenko, T. Harbaum und J. Becker. „Hardware-aware Partitioning of Convolutional Neural Network Inference for Embedded AI Applications“. In: *18th International Conference on Distributed Computing in Sensor Systems (DCOSS)*. 2022. DOI: 10.1109/DCOSS54816.2022.00034.

[80] F. Kreß, V. Sidorenko, P. Schmidt, J. Hoefer, T. Hotfilter, I. Walter, T. Harbaum und J. Becker. „CNNParted: An open source framework for efficient Convolutional Neural Network inference partitioning in embedded systems“. In: *Computer Networks* 229 (2023), S. 109759. DOI: 10.1016/j.comnet.2023.109759.

[81] N. Kucza, F. Porrmann, C. Stollenwerk und J. Hagemeyer. „Efficient Edge AI for Next Generation Smart Mirror Applications“. In: *IEEE Access* (2025). DOI: 10.1109/ACCESS.2025.3574492.

[82] S. Laskaridis, S. I. Venieris, M. Almeida, I. Leontiadis und N. D. Lane. „SPINN: Synergistic Progressive Inference of Neural Networks over Device and Cloud“. In: *Proceedings of the 26th Annual International Conference on Mobile Computing and Networking*. 2020. DOI: 10.1145/3372224.3419194.

[83] E. Li, Z. Zhou und X. Chen. *Edge Intelligence: On-Demand Deep Learning Model Co-Inference with Device-Edge Synergy*. ACM SIGCOMM Workshop on Mobile Edge Communications (MECOMM). Auch als arXiv:1806.07840 verfügbar. 2018. DOI: 10.48550/arXiv.1806.07840.

[84] Z. Li, M. Paolieri und L. Golubchik. *Partition-Aware Scheduling for Mobile Heterogeneous Inference Co-Execution*. Autorenmanuskript, Version 1, 13. September 2026; Performance Evaluation. 2026. arXiv: 2609.14213 [cs.DC]. URL: https://arxiv.org/abs/2609.14213v1.

[85] L. A. Libutti, F. D. Igual, L. Piñuel, L. De Giusti und M. Naiouf. „Benchmarking Performance and Power of USB Accelerators for Inference with MLPerf“. In: *Workshop on Accelerated Machine Learning (AccML)*. 2020. URL: https://accml.dcs.gla.ac.uk/papers/2020/AccML_2020_paper_4.pdf.

[86] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár und C. L. Zitnick. „Microsoft COCO: Common Objects in Context“. In: *Computer Vision – ECCV 2014*. Bd. 8693. Lecture Notes in Computer Science. Springer, 2014, S. 740–755. DOI: 10.1007/978-3-319-10602-1_48.

[87] B. Lizon. *Calibrating an RTD Measurement System*. TI Precision Labs – ADCs. Schulungsunterlagen. Texas Instruments. URL: https://www.ti.com/content/dam/videos/external-videos/en-us/10/3816841626001/calibrating-RTD-measurement-system.mp4/subassets/calibrating-RTD-measurement-system-presentation.pdf (besucht am 07. 11. 2026).

[88] A. Masud, N. Foley, P. D. Rajarajan und P. Lama. *Where to Split? A Pareto-Front Analysis of DNN Partitioning for Edge Inference*. Version 1, 12. Januar 2026. 2026. arXiv: 2601.08025 [cs.DC]. URL: https://arxiv.org/abs/2601.08025v1.

[89] Y. Matsubara, M. Levorato und F. Restuccia. „Split Computing and Early Exiting for Deep Learning Applications: Survey and Research Challenges“. In: *ACM Computing Surveys* (2022). DOI: 10.1145/3527155.

[90] Y. Matsubara, R. Yang, M. Levorato und S. Mandt. „SC2 Benchmark: Supervised Compression for Split Computing“. In: *Transactions on Machine Learning Research* (2023). URL: https://openreview.net/forum?id=p28wv4G65d.

[91] Maxim Integrated. *MAX6639/MAX6639F: 2-Channel Temperature Monitor with Dual, Automatic, PWM Fan-Speed Controller*. 19-3682. Version 3. Apr. 2013. URL: https://www.analog.com/media/en/technical-documentation/data-sheets/MAX6639-MAX6639F.pdf (besucht am 04. 11. 2026).

[92] W. McKinney. „Data Structures for Statistical Computing in Python“. In: *Proceedings of the 9th Python in Science Conference*. 2010, S. 56–61. DOI: 10.25080/Majora-92bf1922-00a.

[93] Microchip Technology. *Hailo-10H*. URL: https://www.microchip.com/en-us/product/hailo-10h (besucht am 11. 11. 2026).

[94] Microchip Technology. *Single-Pair Ethernet (SPE) Products*. URL: https://www.microchip.com/en-us/products/interface-networking-connectivity/ethernet/single-pair-ethernet (besucht am 05. 11. 2026).

[95] K. Mika. „Bounded Offline Audit of Graph Operators, Score Units and Evaluation Provenance“. Interne Prüfunterlagen des Autors. Ergebnisstand: b10d15992d0c; lokaler Implementierungsstand: fe4259d01d37. Quellenzuordnungen, Operator- und Rangfolgeberichte sowie Reproduktionsnachweise. 20. Okt. 2026.

[96] K. Mika. *Edge AI Performance and Energy Results*. Versionierte numerische Ergebnisse, Analyseskripte und ergänzende Studien. Commit aed3018 (vollständige Revision in der URL), geprüft am 28. Oktober 2026. Kompakte Ergebnisnachweise sind von vollständigen Erfassungsarchiven zu unterscheiden. 2026. URL: https://github.com/Keff789/edge-ai-performance-energy-results/tree/aed301819663b5fa27bd5731fb74fef3e46ee927 (besucht am 28. 10. 2026).

[97] K. Mika. *Edge AI Performance and Energy Results: Selected-Winner Confirmation and Measurement Documentation*. Festgelegte Repository-Revision 6ebc90deca31. Enthält die abgeschlossene Bestätigungsprüfung, bedingte Energieergänzungen, die Prüfung des Evaluators, gepaarte Qualitätsintervalle und Operatorbestätigungen. 19. Okt. 2026. URL: https://github.com/Keff789/edge-ai-performance-energy-results/tree/6ebc90deca31c9890d7ebccd7fd2981f8bda0c96/results/supplementary-studies/thesis-v49-confirmation-20261019 (besucht am 19. 10. 2026).

[98] K. Mika, J. Hagemeyer und U. Rückert. *Good Splits Are Hard to Find: Understanding Performance–Energy Trade-offs in Heterogeneous Edge Inference*. Autorenmanuskript und Ergänzung, verwendete Endfassung vom 28. Oktober 2026. Für MLSys vorbereitet. Numerische Ergebnisse und Analyseskripte sind im begleitenden öffentlichen Ergebnisrepositorium verfügbar. 2026.

[99] K. Mika und J. Wachsmuth. *Energy-Measurement Evidence: Reconstruction, Spectra, Deployed Meters and Protocol Controls*. Versionierte Ergebnisexporte, Methoden und Abbildungs-/Tabellenkataloge. Festgelegter Repository-Commit nach der Neuorganisation; die kompakten Nachweise sind nicht das Archiv der Rohwellenformen. 2026. URL: https://github.com/Keff789/onnx-splitpoint-results/tree/fb98d60d4dbdc10b460ee2d136843363cfeed2bf/energy-measurement (besucht am 09. 10. 2026).

[100] K. Mika, J. Wachsmuth, J. Hagemeyer und U. Rückert. *How Fast Is Fast Enough? Reference-Calibrated Energy Measurement for Edge-AI Inference*. Autorenmanuskript v0.15.5, bereitgestellt am 18. Oktober 2026. Für PARMA-DITAM vorbereitet; es wird keine Aussage zum Veröffentlichungsstatus getroffen. 2026. URL: https://github.com/Keff789/edge-ai-performance-energy-results/tree/820f6ecaf3e1e4cba2796a7418ff42913cf43e51/publications/parma-ditam (besucht am 18. 10. 2026).

[101] K. Mika, J. Wachsmuth, F. Porrmann und J. Hagemeyer. *Reference-Based Sampling-Rate Selection and Measurement Validation for Edge-AI Accelerators*. Arbeitsfassung eines Zeitschriftenmanuskripts, bereitgestellt am 18. Oktober 2026. Für IEEE Transactions on Instrumentation and Measurement ausgearbeitet; kein veröffentlichter Zeitschriftenartikel. Spätere numerische Korrekturen sind in den begleitenden Nachweisen dokumentiert. 2026. URL: https://github.com/Keff789/edge-ai-performance-energy-results/tree/820f6ecaf3e1e4cba2796a7418ff42913cf43e51/publications/tim (besucht am 18. 10. 2026).

[102] MLCommons. *MLPerf Inference Power Measurement Rules*. Zugriff am 2026-02-26. 2026. URL: https://github.com/mlcommons/power-dev/blob/master/power_measurement.adoc.

[103] MLCommons. *MLPerf Inference Rules*. Zugriff am 2026-06-22. 2026. URL: https://github.com/mlcommons/inference_policies/blob/master/inference_rules.adoc.

[104] MLCommons. *MLPerf Inference: Edge Benchmark*. Zugriff am 2026-06-22. 2026. URL: https://mlcommons.org/benchmarks/inference-edge/.

[105] MLCommons. *MLPerf Inference: Power Measurement*. Zugriff am 2026-02-17. 2026. URL: https://mlcommons.org/docs/inference/inference-power/.

[106] T. Neu. *Clock jitter analyzed in the time domain, Part 1*. 2010. URL: https://www.ti.com/lit/an/slyt379/slyt379.pdf (besucht am 06. 06. 2026).

[107] NVIDIA. *CUDA C++ Programming Guide*. Version 12.6.0. Insbesondere Abschnitt 3.2.6: Page-Locked Host Memory. URL: https://docs.nvidia.com/cuda/archive/12.6.0/cuda-c-programming-guide/index.html (besucht am 04. 11. 2026).

[108] NVIDIA. *JetPack SDK 6.2.1*. URL: https://developer.nvidia.com/embedded/jetpack-sdk-621 (besucht am 04. 11. 2026).

[109] NVIDIA. *Jetson Orin NX Series Module Data Sheet*. Zugriff am 2026-02-17. 2026. URL: https://developer.nvidia.com/embedded/downloads#?search=Jetson%20Orin%20NX%20Series%20Module%20Data%20Sheet.

[110] NVIDIA. *NVIDIA Jetson Modules*. URL: https://developer.nvidia.com/embedded/jetson-modules/ (besucht am 05. 11. 2026).

[111] NVIDIA. *Tegrastats Utility — NVIDIA Jetson Linux Developer Guide*. 2024. URL: https://docs.nvidia.com/jetson/archives/r34.1/DeveloperGuide/text/AT/JetsonLinuxDevelopmentTools/TegrastatsUtility.html (besucht am 27. 02. 2026).

[112] NVIDIA. *TensorRT Developer Guide*. Zugriff am 2026-02-17. 2026. URL: https://docs.nvidia.com/deeplearning/tensorrt/developer-guide/index.html.

[113] Ollama. *Ollama: Source Code and Documentation*. URL: https://github.com/ollama/ollama (besucht am 04. 11. 2026).

[114] ONNX Community. *Open Neural Network Exchange (ONNX)*. Zugriff am 2026-01-22. 2025. URL: https://onnx.ai/.

[115] ONNX Project. *ONNX Operator Documentation: ReduceMax, Version 18*. URL: https://onnx.ai/onnx/operators/onnx__ReduceMax.html#reducemax-18 (besucht am 04. 11. 2026).

[116] ONNX Project. *ONNX Operator Documentation: TopK, Version 11*. URL: https://onnx.ai/onnx/operators/onnx__TopK.html#topk-11 (besucht am 04. 11. 2026).

[117] *ONNX Runtime CUDA Execution Provider*. https://onnxruntime.ai/docs/execution-providers/CUDA-ExecutionProvider.html. Zugriff am 2026-02-26. 2026.

[118] *ONNX Runtime Execution Providers*. https://onnxruntime.ai/docs/execution-providers/. Zugriff am 2026-02-26. 2026.

[119] *ONNX Runtime TensorRT Execution Provider*. https://onnxruntime.ai/docs/execution-providers/TensorRT-ExecutionProvider.html. Zugriff am 2026-02-26. 2026.

[120] OpenAI. *ChatGPT Capabilities Overview*. URL: https://help.openai.com/en/articles/9260256-chatgpt-capabilities-overview (besucht am 04. 11. 2026).

[121] OpenAI. *Codex Is Now Generally Available*. 6. Okt. 2025. URL: https://openai.com/index/codex-now-generally-available/ (besucht am 04. 11. 2026).

[122] A. Parashar, P. Raina, Y. S. Shao, Y.-H. Chen, V. A. Ying, A. Mukkara, R. Venkatesan, B. Khailany, S. W. Keckler und J. Emer. „Timeloop: A Systematic Approach to DNN Accelerator Evaluation“. In: *2019 IEEE International Symposium on Performance Analysis of Systems and Software (ISPASS)*. 2019, S. 304–315. DOI: 10.1109/ISPASS.2019.00042.

[123] PCI Industrial Computer Manufacturers Group (PICMG). *COM Express Module Base Specification and Form-Factor Overview*. Offizielle Übersicht über den COM-Express-Standard, Modulgrößen, Steckverbindervarianten und den Anwendungsbereich. Zugriff am 2026-07-16. 2026. URL: https://www.picmg.org/openstandards/com-express/.

[124] PCI Industrial Computer Manufacturers Group (PICMG). *COM-HPC® Overview*. https://www.picmg.org/openstandards/com-hpc/. COM-HPC ist ein offener Standard für leistungsfähige Computer-on-Modules. Der 2021 ratifizierte Standard zielt auf Bandbreiten und Leistungsbudgets der Serverklasse ab. COM-HPC-Module sind in größeren Abmessungen erhältlich (bis zu 200 mm × 160 mm) und unterstützen Leistungsbudgets bis zu 300 W und Speicherkapazitäten bis zu 1 TB. Zu den neuen Funktionen gehören PCI Express Gen 5, USB4, DisplayPort 2.0 und 25-GbE-Schnittstellen, die leistungsfähige heterogene Prozessoren und Beschleuniger ermöglichen. 2023.

[125] Pico Technology. *PicoScope 4224A, 4424A and 4824A Oscilloscopes*. 2026. URL: https://www.picotech.com/oscilloscope/4000/picoscope-4000-series (besucht am 28. 08. 2026).

[126] PyMuPDF contributors. *PyMuPDF Documentation*. URL: https://pymupdf.readthedocs.io/en/latest/ (besucht am 04. 11. 2026).

[127] Python Software Foundation. *Python 3 Documentation*. URL: https://docs.python.org/3/ (besucht am 04. 11. 2026).

[128] I. Radosavovic, R. P. Kosaraju, R. Girshick, K. He und P. Dollár. „Designing Network Design Spaces“. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2020, S. 10428–10436. URL: https://openaccess.thecvf.com/content_CVPR_2020/html/Radosavovic_Designing_Network_Design_Spaces_CVPR_2020_paper.html.

[129] Raspberry Pi Ltd. *Raspberry Pi Compute Module 4: Product Brief*. Juli 2026. URL: https://pip.raspberrypi.com/documents/RP-008169-DS-cm4-product-brief.pdf (besucht am 04. 11. 2026).

[130] V. J. Reddi, C. Cheng, D. Kanter, P. Mattson, G. Schmuelling, C.-J. Wu, B. Anderson, M. Breughe, M. Charlebois, W. Chou u. a. *MLPerf Inference Benchmark*. 2019. arXiv: 1911.02549 [cs.LG].

[131] J. Redmon, S. Divvala, R. Girshick und A. Farhadi. „You Only Look Once: Unified, Real-Time Object Detection“. In: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 2016, S. 779–788. DOI: 10.1109/CVPR.2016.91.

[132] A. Reuther, P. Michaleas, M. Jones, V. Gadepally und J. Kepner. *Lincoln AI Computing Survey (LAICS) and Trends*. Zugriff am 2026-06-09. 2025. arXiv: 2510.20931 [cs.DC]. URL: https://arxiv.org/abs/2510.20931.

[133] A. Reuther, P. Michaleas, M. Jones, V. Gadepally, S. Samsi und J. Kepner. „AI Accelerator Survey and Trends“. In: *2021 IEEE High Performance Extreme Computing Conference (HPEC)*. Zugriff am 2026-06-10. 2021, S. 1–9. DOI: 10.1109/HPEC49654.2021.9622867. arXiv: 2109.08957 [cs.AR].

[134] A. Reuther, P. Michaleas, M. Jones, V. Gadepally, S. Samsi und J. Kepner. „Lincoln AI Computing Survey (LAICS) Update“. In: *2023 IEEE High Performance Extreme Computing Conference (HPEC)*. Zugriff am 2026-06-10. 2023, S. 1–7. DOI: 10.1109/HPEC58863.2023.10363568. arXiv: 2310.09145 [cs.DC].

[135] A. Reuther, P. Michaleas, M. Jones, V. Gadepally, S. Samsi und J. Kepner. „Survey and Benchmarking of Machine Learning Accelerators“. In: *2019 IEEE High Performance Extreme Computing Conference (HPEC)*. Zugriff am 2026-06-10. 2019, S. 1–9. DOI: 10.1109/HPEC.2019.8916327. arXiv: 1908.11348 [cs.PF].

[136] O. Russakovsky, J. Deng, H. Su, J. Krause, S. Satheesh, S. Ma, Z. Huang, A. Karpathy, A. Khosla, M. Bernstein, A. C. Berg und L. Fei-Fei. „ImageNet Large Scale Visual Recognition Challenge“. In: *International Journal of Computer Vision* 115.3 (2015), S. 211–252. DOI: 10.1007/s11263-015-0816-y.

[137] SECO. *SOM-SMARC-ZU (B71)*. URL: https://developer.seco.com/hardware/product/computer-on-modules/smarc-modules/som-smarc-zu-b71/ (besucht am 05. 11. 2026).

[138] W. Seo, S. Kim und S. Hong. „DNNPipe: Dynamic programming-based optimal DNN partitioning for pipelined inference on IoT networks“. In: *Journal of Systems Architecture* 166 (2025), S. 103462. DOI: 10.1016/j.sysarc.2025.103462.

[139] N. Shalavi, A. Khoshsirat, M. Stellini, A. Zanella und M. Rossi. „Accurate Calibration of Power Measurements from Internal Power Sensors on NVIDIA Jetson Devices“. In: *2023 IEEE International Conference on Edge Computing and Communications (EDGE)*. 2023, S. 166–170. DOI: 10.1109/EDGE60047.2023.00034.

[140] J. Shao und J. Zhang. „BottleNet++: An End-to-End Approach for Feature Compression in Device-Edge Co-Inference Systems“. In: *2020 IEEE International Conference on Communications Workshops (ICC Workshops)*. 2020, S. 1–6. DOI: 10.1109/ICCWorkshops49005.2020.9145068.

[141] Shelly. *Shelly Plus Plug S: Technical Documentation*. URL: https://shelly-api-docs.shelly.cloud/gen2/Devices/Gen2/ShellyPlusPlugS/ (besucht am 04. 11. 2026).

[142] Standardization Group for Embedded Technologies (SGET). *Qseven Computer-On-Module Standard*. https://sget.org/standards/qseven/. Das Qseven-Konzept definiert einen Standard für serienmäßig verfügbare Computer-on-Modules, der alle zentralen PC-Funktionen auf einem Modul mit 70 mm × 70 mm oder 40 mm × 70 mm integriert. Ein einzelner robuster MXM-Steckverbinder mit standardisierter Pinbelegung verbindet das Modul mit einer Trägerplatine und führt alle I/O-Signale. Qseven-Module umfassen Grafik, Audio, Massenspeicher, Netzwerk und mehrere USB-Anschlüsse und unterstützen sowohl x86- als auch ARM-Prozessoren, wodurch sie sich für mobile und IoT-Anwendungen eignen. 2021.

[143] Standardization Group for Embedded Technologies (SGET). *Smart Mobility ARChitecture (SMARC) Standard*. https://sget.org/standards/smarc/. Definiert die SMARC-Modulspezifikation: Das SMARC-Modul ist ein vielseitiges Computer-on-Module mit kleinem Formfaktor für Anwendungen, die geringe Leistungsaufnahme, niedrige Kosten und hohe Rechenleistung erfordern. Die Module verwenden typischerweise ARM-SoCs oder alternativ stromsparende x86-Bausteine mit typischen Leistungsbudgets unter 6 W. Zwei Modulgrößen sind definiert (82 mm × 50 mm und 82 mm × 80 mm), die jeweils einen Platinenrand-Steckverbinder mit 314 Kontakten verwenden. SMARC-Module integrieren CPU, DRAM, Boot-Flash und GBE und nutzen anwendungsspezifische Trägerplatinen für Audio-, Touchscreen- oder Drahtlosfunktionen. 2026.

[144] V. Sze, Y.-H. Chen, T.-J. Yang und J. S. Emer. „Efficient Processing of Deep Neural Networks: A Tutorial and Survey“. In: *Proceedings of the IEEE* 105.12 (2017), S. 2295–2329. DOI: 10.1109/JPROC.2017.2761740.

[145] Z. Taufique, A. Vyas, A. Miele, P. Liljeberg und A. Kanduri. „HiDP: Hierarchical DNN Partitioning for Distributed Inference on Heterogeneous Edge Platforms“. In: *2025 Design, Automation & Test in Europe Conference & Exhibition (DATE)*. 2025. DOI: 10.23919/DATE64628.2025.10992692.

[146] S. Teerapittayanon, B. McDanel und H. T. Kung. „Distributed Deep Neural Networks over the Cloud, the Edge and End Devices“. In: *2017 IEEE 37th International Conference on Distributed Computing Systems (ICDCS)*. IEEE. 2017, S. 328–339. URL: https://www.eecs.harvard.edu/~htk/publication/2017-icdcs-teerapittayanon-mcdanel-kung.pdf.

[147] Tektronix. *6 Series B MSO Mixed Signal Oscilloscope Datasheet*. 2026. URL: https://www.tek.com/en/datasheet/6series-b-mso-mixed-signal-oscilloscope-datasheet (besucht am 28. 08. 2026).

[148] Tektronix. *TCP0030A 30 A AC/DC Current Probe Datasheet*. 2025. URL: https://www.tek.com/en/datasheet/30-ac-dc-current-probe (besucht am 28. 08. 2026).

[149] Tektronix. *TPP0051 Passive 10X Voltage Probe Datasheet*. 2013. URL: https://www.tek.com/en/datasheet/tpp0051-passive-probe-datasheet (besucht am 28. 08. 2026).

[150] Texas Instruments. *INA225 36-V, Programmable-Gain, Voltage-Output Current-Shunt Monitor Datasheet*. SBOS612A. 2014. URL: https://www.ti.com/lit/gpn/INA225 (besucht am 28. 08. 2026).

[151] Texas Instruments. *TPS65987D USB Type-C and USB PD Controller with Integrated Source and Sink Power Path Supporting USB3 and Alternate Mode*. SLVSES1D. Version D. Okt. 2022. URL: https://www.ti.com/lit/ds/symlink/tps65987d.pdf (besucht am 04. 11. 2026).

[152] Texas Instruments. *TPS748: 1.5A, Low-Dropout Linear Regulator With Programmable Soft-Start*. SBVS074N. Version N. Juni 2024. URL: https://www.ti.com/lit/ds/symlink/tps74801.pdf (besucht am 04. 11. 2026).

[153] Texas Instruments Incorporated. *ADS79xx Pin Compatible, 12-, 10-, 8-Bit, 1-MSPS, 16-, 12-, 8-, 4-Channel, Single-Ended, Serial Interface ADCs*. Version JULY 2018. Datenblatt. Texas Instruments Incorporated. URL: https://www.ti.com/lit/ds/symlink/ads7953.pdf (besucht am 23. 05. 2026).

[154] Texas Instruments Incorporated. *INA3221 26V, Triple Channel, 13-Bit, I2C Output Current and Voltage Monitor With Alerts*. Version SEPTEMBER 2025. Datenblatt. Texas Instruments Incorporated. URL: https://www.ti.com/lit/ds/symlink/ina3221.pdf (besucht am 19. 05. 2026).

[155] H. Topcuoglu, S. Hariri und M.-Y. Wu. „Performance-Effective and Low-Complexity Task Scheduling for Heterogeneous Computing“. In: *IEEE Transactions on Parallel and Distributed Systems* 13.3 (2002), S. 260–274.

[156] A. Tschand, A. T. R. Rajan, S. Idgunji, A. Ghosh, J. Holleman, C. Király, P. Ambalkar, R. Borkar, R. Chukka, T. Cockrell, O. Curtis, G. Fursin, M. Hodak, H. Kassa, A. Lokhmotov, D. Miskovic, Y. Pan, M. P. Manmathan, L. Raymond, T. St. John, A. Suresh, R. Taubitz, S. Zhan, S. Wasson, D. Kanter und V. J. Reddi. „MLPerf Power: Benchmarking the Energy Efficiency of Machine Learning Systems from μWatts to MWatts for Sustainable AI“. In: *2025 IEEE International Symposium on High-Performance Computer Architecture (HPCA)*. IEEE, 2025, S. 1201–1216. DOI: 10.1109/HPCA61900.2025.00092.

[157] Ultralytics. *DFL: Distribution Focal Loss Integral Module. Ultralytics Neural Network Module Reference*. URL: https://docs.ultralytics.com/reference/nn/modules/block/ (besucht am 04. 11. 2026).

[158] P. Virtanen, R. Gommers, T. E. Oliphant, M. Haberland, T. Reddy, D. Cournapeau, E. Burovski, P. Peterson, W. Weckesser, J. Bright, S. J. van der Walt, M. Brett, J. Wilson, K. J. Millman, N. Mayorov, A. R. J. Nelson, E. Jones, R. Kern, E. Larson, C. J. Carey, İ. Polat, Y. Feng, E. W. Moore, J. VanderPlas, D. Laxalde, J. Perktold, R. Cimrman, I. Henriksen, E. A. Quintero, C. R. Harris, A. M. Archibald, A. H. Ribeiro, F. Pedregosa, P. van Mulbregt und SciPy 1.0 Contributors. „SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python“. In: *Nature Methods* 17.3 (2020), S. 261–272. DOI: 10.1038/s41592-019-0686-2.

[159] S. van der Vlugt, L. C. Oostrum, G. Schoonderbeek, B. van Werkhoven, B. Veenboer, K. Doekemeijer und J. W. Romein. *PowerSensor3: A Fast and Accurate Open Source Power Measurement Tool*. Auch auf der ISPASS 2025 vorgestellt (DOI: 10.1109/ISPASS64960.2025.00028). 2025. DOI: 10.48550/arXiv.2504.17883. arXiv: 2504.17883 [cs.PF].

[160] J. Wachsmuth. „Entwicklung und Validierung eines Messsystems zur energetischen Bewertung eingebetteter KI-Beschleuniger“. Master's thesis. Bielefeld University, 2026.

[161] C.-Y. Wang, A. Bochkovskiy und H.-Y. M. Liao. „YOLOv7: Trainable Bag-of-Freebies Sets New State-of-the-Art for Real-Time Object Detectors“. In: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2023, S. 7464–7475. URL: https://openaccess.thecvf.com/content/CVPR2023/html/Wang_YOLOv7_Trainable_Bag-of-Freebies_Sets_New_State-of-the-Art_for_Real-Time_Object_Detectors_CVPR_2023_paper.html.

[162] H. Wang, C. Imes, S. Kundu, P. A. Beerel, S. P. Crago und J. P. Walters. „QuantPipe: Applying Adaptive Post-Training Quantization for Distributed Transformer Pipelines in Dynamic Edge Environments“. In: *2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2023. DOI: 10.1109/ICASSP49357.2023.10096632.

[163] P. D. Welch. „The Use of Fast Fourier Transform for the Estimation of Power Spectra: A Method Based on Time Averaging over Short, Modified Periodograms“. In: *IEEE Transactions on Audio and Electroacoustics* 15.2 (1967), S. 70–73. DOI: 10.1109/TAU.1967.1161901.

[164] Y. N. Wu, J. S. Emer und V. Sze. „Accelergy: An Architecture-Level Energy Estimation Methodology for Accelerator Designs“. In: *2019 IEEE/ACM International Conference on Computer-Aided Design (ICCAD)*. 2019, S. 1–8. DOI: 10.1109/ICCAD45719.2019.8942149.

[165] Y. Wu, Y. Gong, Z. Zhan, G. Yuan, Y. Li, Q. Wang, C. Wu und Y. Wang. „MOC: Multi-Objective Mobile CPU–GPU Co-Optimization for Power-Efficient DNN Inference“. In: *2023 IEEE/ACM International Conference on Computer Aided Design (ICCAD)*. IEEE, 2023, S. 1–10. DOI: 10.1109/ICCAD57390.2023.10323882.

[166] Z. Yang, K. Adámek und W. Armour. „Part-Time Power Measurements: NVIDIA-SMI's Lack of Attention“. In: *arXiv preprint arXiv:2312.02741* (2024). arXiv: 2312.02741 [cs.DC]. URL: https://arxiv.org/abs/2312.02741.

[167] P. Zeng, B. Luo, H. Yuan, X. Su und L. Wang. „CoEdge: Cooperative DNN Inference with Adaptive Workload Partitioning over Heterogeneous Edge Devices“. In: *IEEE/ACM Transactions on Networking* 29.2 (2021), S. 595–608. DOI: 10.1109/TNET.2021.3053946.

[168] B. Zhang, H. Zhu, F. Gao, Z. Yang und S. X. Wang. *Moirai: Towards Optimal Placement for Distributed Inference on Heterogeneous Devices*. Version 3, 26. Dezember 2023. 2023. arXiv: 2312.04025 [cs.DC]. URL: https://arxiv.org/abs/2312.04025v3.

[169] Z. Zhao, K. Mirzazad Barijough und A. Gerstlauer. „DeepThings: Distributed Adaptive Deep Learning Inference on Resource-Constrained IoT Edge Clusters“. In: *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems* 37.11 (2018), S. 2348–2359. DOI: 10.1109/TCAD.2018.2858384.

[170] E. Zitzler, L. Thiele, M. Laumanns, C. M. Fonseca und V. G. da Fonseca. „Performance assessment of multiobjective optimizers: An analysis and review“. In: *IEEE Transactions on Evolutionary Computation* 7.2 (2003), S. 117–132. DOI: 10.1109/TEVC.2003.810758.

Der Dissertation zugrunde liegende eigene Veröffentlichungen

[171] K. Mika, J. Hagemeyer, N. Kucza und F. Porrmann. „Automated Neural Network Partitioning Across Distributed Heterogeneous Edge Accelerators“. In: *Architecture of Computing Systems: 39th International Conference, ARCS 2026, Mainz, Germany, March 24–26, 2026, Proceedings*. Hrsg. von A. Brinkmann, M. Porrmann, C. Herglotz, F. Mantovani und T. Pionteck. Bd. 16482. Lecture Notes in Computer Science. Im Erscheinen. Zum Zeitpunkt dieser Überarbeitung lag keine DOI für das einzelne Kapitel vor. Springer, 2026. ISBN: 978-3-032-32693-5.

[172] K. Mika, N. Kucza, F. Porrmann und J. Hagemeyer. „Optimizing AI on the Edge: Partitioning Neural Networks Across Heterogeneous Accelerators“. In: *Advances in Computational Intelligence: 18th International Work-Conference on Artificial Neural Networks, IWANN 2025*. Hrsg. von I. Rojas, G. Joya und A. Catala. Bd. 16008. Lecture Notes in Computer Science. Springer, 2026, S. 205–217. DOI: 10.1007/978-3-032-02725-2_16.

[173] K. Mika, F. Porrmann, N. Kucza, R. Griessl und J. Hagemeyer. „RECS: A Scalable Platform for Heterogeneous Computing“. In: *2023 IEEE 36th International System-on-Chip Conference (SOCC)*. 2023, S. 1–6. DOI: 10.1109/SOCC58585.2023.10256982.